

Гибридный онлайн-декодер ЭЭГ + NIRS

Как решение отличает покой от представления движения левой и правой кисти: предобработка сигналов, извлечение признаков, классификация, дообучение по блокам, защита от утечек и проверки того, что модель декодирует работу мозга, а не артефакты.

0.507

F_{global} — худшая F1 гибрида, в среднем по сессиям (LOSO)

0.640


P_{global} — macro-recall гибрида (LOSO)

0.403

худшая F1 отдельного NIRS-ответа y_{nirs}

60.65

расчётный балл без оценки жюри; штрафов по времени нет



Содержание

Кратко о решении	3
Часть I. Задача и данные	5
1. Что нужно было построить	5
2. Данные	7
3. Нейрофизиология: что мы ищем в сигналах	9
4. Что показал анализ данных и как это повлияло на архитектуру	11
Часть II. Как устроено решение	16
5. Архитектура целиком	16
6. Предобработка ЭЭГ: от отсчётов АЦП к ковариациям	19
7. Признаки ЭЭГ: риманова геометрия ковариаций	23
8. Классификаторы ЭЭГ	26
9. NIRS-ветка	30
10. Слияние ЭЭГ и NIRS	33
11. Калибровка смещений под min-F1	34
12. Временная интеграция: почему в финале нет сглаживания	35
13. Что происходит в fit_block: дообучение по блокам	36
14. Что происходит в predict	37
15. Одна сессия от начала до конца	38
Часть III. Честность, результаты и проверки	39
16. Защита от утечек	39
17. Как оценивалось качество	40
18. Результаты	41
19. Контроли: модель декодирует моторное представление, а не артефакты	46
20. Что пробовали и почему отказались	49
21. Ограничения, риски и что можно улучшить	50
Часть IV. Справочник	52
22. Карта кода	52
23. Все параметры конфигурации	53
24. Как запустить и воспроизвести	54
25. Глоссарий	55
26. Источники	56

Кратко о решении

Решение — онлайн-классификатор, который каждые 250 мс по последней секунде синхронных ЭЭГ и NIRS отвечает, в каком из трёх состояний находится человек: **покой**, **кинестетическое представление раскрытия левой кисти** или **правой кисти**. Он видит только прошлое, дообучается после каждого завершённого блока, укладывается во временной бюджет и при отсутствии NIRS работает на одной ЭЭГ.

Главная идея решения — извлекать из ЭЭГ то, что физиологически и должно различать эти состояния: **десинхронизацию сенсомоторных μ - и β -ритмов (ERD)** над моторной корой, причём контралатерально руке. Для этого по каждому окну строятся ковариационные матрицы сигналов в шести частотных полосах 4–30 Гц на 11 сенсомоторных каналах. Эти матрицы переводятся в **касательное пространство риманова многообразия** относительно «среднего состояния» текущей сессии. Получается 396 признаков, где падение мощности ритма на конкретном электроде — это просто сдвиг соответствующей координаты. На признаках работают три модели: две учатся на прошедших блоках текущей сессии, третья заранее обучена на других людях. NIRS добавляет медленную гемодинамическую информацию: наклоны кривых HbO/HbR с задержками до 6 с. Ответы модальностей сливаются лог-линейно, а пороги решения подстраиваются под метрику соревнования — худшую по классам F1.

РЕШЕНИЕ В ДЕСЯТИ ПУНКТАХ

- 1. Только причинная обработка.** Все фильтры — IIR в форме SOS с сохранённым состоянием. Центры, нормировки и маски каналов строятся по уже полученным данным. Метки используются только в `fit_block` и только для завершённых блоков.
- 2. Фронтенд ЭЭГ:** вычитание первого отсчёта → ВЧ-фильтр 0.5 Гц → банк полос 4–8, 8–12, 12–16, 16–20, 20–24, 24–30 Гц → ковариации всех 21 канала в каждой точке сетки окон (шаг 62 отсчёта = 0.248 с).
- 3. Каналы и референс:** 11 сенсомоторных каналов (c3, cz, c4, f3, fz, f4, p3, pz, p4, T7, T8). Референс — общее среднее по 13 «чистым» каналам. Шумные и клиппированные каналы находятся автоматически по прошлым данным.
- 4. Римановы признаки:** ковариации усредняются по 5 последним окнам сетки (≈ 2 с) и регуляризуются усадкой OAS. Затем они «отбеливаются» средним всех прошлых окон сессии и логарифмируются: 6 полос $\times$ 66 = **396 признаков**.
- 5. Сессионная модель:** shrinkage-LDA и классификатор «ближайшего среднего» (MDM) в касательном пространстве. Логиты нормированы — это аналог temperature scaling.
- 6. Межсубъектная модель:** логистическая регрессия на 101 194 окнах всех 56 сессий train. Перенос на нового человека обеспечивает перецентрирование. Её вес $w = 1/(1 + \text{число прошедших блоков})$: 0.5 в блоке 2 и 0.14 в блоке 7.
- 7. NIRS-ветка:** НЧ-фильтр 0.4 Гц, МНК-наклоны за 4 с с лагами 0/2/4/6 с по 18 каналам HbO и 18 HbR плюс два межполушарных контраста — **152 признака**. На них обучается sLDA, который даёт отдельный ответ `y_nirs`.
- 8. Слияние:** $\log p = 0.8 \log p_{\text{ЭЭГ}} + 0.2 \log p_{\text{NIRS}}$ с последующей нормировкой.
- 9. Калибровка под min-F1:** начиная с 3-го блока, по вне-выборочным предсказаниям (leave-one-block-out) подбираются смещения логитов, максимизирующие худшую F1. Результат усаживается к нулю.
- 10. Проверка честности:** ответы побитово не зависят от нарезки данных на порции (56/56 сессий, 0 расхождений на 86 746 окнах). Метки будущих блоков не влияют на прошлые ответы. Качество

оценено для **новых людей** (leave-one-subject-out).

ИТОГОВЫЕ ЧИСЛА (ОНЛАЙН-СИМУЛЯЦИЯ НА 56 СЕССИЯХ TRAIN)

вариант	F_{global}	P_{global}	$F_{\text{global}}^{\text{NIRS}}$	балл*	как оценено
исходный MVP	0.472	0.618	0.383	57.58	содержит утечку через тайминг
MVP без утечки	0.421	0.551	0.360	52.2	честно, только сессионные данные
финальное решение	0.507	0.640	0.403	60.65	LOSO: новые испытуемые
финальное решение, results/metrics	0.539	0.664	0.403	63.30	глобальная модель видела этих людей

* Балл = $60 \cdot F + 30 \cdot P + 5 + 15 \cdot F^{\text{NIRS}}$, без 20 баллов жюри за дизайн и отчёт. Штрафов за время нет: $\text{predict} \leq 0.03$ с, $\text{fit_block} \leq 0.6$ с на машине разработчика (подробнее и об оговорке по скорости — §21).

Как читать документ. Документ состоит из четырёх частей.

- **Часть I** — задача и данные: что классифицируется, как устроен эксперимент, что в данных нашлось неожиданного и почему это определило архитектуру.
- **Часть II** — ядро документа: шаг за шагом, с формулами и числами, как из сырых отсчётов получаются признаки, как устроены модели, слияние, калибровка и дообучение.
- **Часть III** — доказательная: как исключены утечки, как оценивалось качество, какие получены результаты и какие контрольные эксперименты показывают, что модель опирается на сенсомоторные ритмы, а не на артефакты стимулятора или движения глаз.
- **Часть IV** — справочник: карта кода, все параметры, команды воспроизведения, глоссарий и литература.

Обозначения, которые встречаются везде:

- **КМП** — кинестетическое моторное представление;
- **ERD** — десинхронизация ритма, то есть падение его мощности;
- **ФЭС** — функциональная электростимуляция;
- **LOSO** — оценка на испытуемом, которого не было в обучении (leave-one-subject-out);
- **LOBO** — leave-one-block-out внутри сессии;
- **min-F1** — худшая по трём классам F1-мера.

Номера экспериментов вида `E10_fusion` ссылаются на каталоги `results/experiments/` репозитория.

ЧАСТЬ I

Задача и данные

1. Что нужно было построить

1.1 Клинический контекст

Интерфейс мозг–компьютер (ИМК) в реальном времени переводит активность мозга в управляющий сигнал. В этом исследовании сигнал управлял функциональной электростимуляцией (ФЭС) разгибателей кисти. Человек мысленно «раскрывает» кисть, ИМК распознаёт это, и стимулятор реально разгибает запястье. По мета-анализам именно связка ИМК+ФЭС даёт наибольший реабилитационный эффект после инсульта: корковая активация совпадает по времени с реальным сокращением мышц.

Датасет получен в слепом рандомизированном исследовании РНИМУ им. Н. И. Пирогова на здоровых добровольцах (Mokienko et al., *Sensors*, 2026). Записывались одновременно:

- **ЭЭГ** — электрическая активность, миллисекундное разрешение;
- **NIRS (fNIRS, БИКС)** — оптическая оценка концентраций окси- и дезоксигемоглобина в коре, медленная, но устойчивая к электрическим помехам.

Вопрос хакатона: даёт ли объединение модальностей выигрыш в **онлайн-режиме** на трёх классах при честных ограничениях реального времени.

1.2 Что именно классифицируется

класс	метка States	что делает испытуемый	подсказка на экране	доля оцениваемых окон
1 — покой	1	ничего не представляет, расслаблен	стрелка вверх зеленеет	≈ 50 %
2 — левая кисть	2	кинестетически представляет разгибание левого запястья	стрелка влево зеленеет	≈ 25 %
3 — правая кисть	3	то же для правой руки	стрелка вправо зеленеет	≈ 25 %
— (не оценивается)	0	подготовка 1.5 с перед каждой задачей	стрелка синее	—

Кинестетическое представление — это представление *ощущения* движения: напряжения мышц, положения сустава, «как будто я это делаю». Зрительный образ движения сюда не относится. Такое представление вовлекает сенсомоторную кору и даёт локализованную над ней десинхронизацию ритмов. Поэтому целевые признаки — ритмы над электродами C3/C4/Cz, а не лобные или затылочные сигналы (§3).

1.3 Онлайн-контракт

Решение реализует класс `OnlineClassifier` с тремя методами. Замороженный каркас `solution/run.py` вызывает их в строго хронологическом порядке:

```
class OnlineClassifier:
    def __init__(self, meta): ... # частоты, имена каналов, наличие NIRS
    def load(self, artifacts_dir): ... # офлайн-обученные компоненты (глобальная модель)
    def push(self, eeg_chunk, nirs_chunk): ... # только НОВЫЕ отсчеты ЭЭГ и NIRS
    def predict(self) → dict: ... # {"y": 1|2|3, "y_nirs": 1|2|3, ...}
    def fit_block(self, block_idx, labels): ... # метки ТОЛЬКО что завершённого блока
```

Как каркас подаёт данные (run.py):

- Строится список событий. `predict` ставится в конце каждого оцениваемого окна, `fit_block` — в конце каждого блока, включая 1-й и 7-й. События сортируются по времени; при совпадении времени `predict` идёт раньше `fit_block`.
- Перед каждым событием в `push` передаются все ещё не отданные отсчеты ЭЭГ. Вместе с ними приходят все отсчеты NIRS, у которых индекс синхронизации `Frame` попадает в тот же интервал. Отдельного потока NIRS нет.
- В `fit_block` приходят метки `States` и индексы отсчетов завершённого блока, только для отсчетов с `States > 0`.
- Время каждого вызова `predict` и `fit_block` измеряется и штрафуются, если превышает бюджет.

1.4 Окна и сетка времени

Частота ЭЭГ — 250 Гц, окно — `win = round(250 · 1.0) = 250` отсчетов. Шаг — `step = round(250 · 0.25) = round(62.5)`. Python округляет половины к чётному, поэтому шаг равен **62 отсчёта, то есть 0.248 с**, а не 0.25 с. Концы окон лежат на фиксированной сетке:

$$e_k = 250 + 62k, \quad k = 0, 1, 2, \dots$$

Окно $[e_k - 250, e_k)$ **оценивается**, если оно целиком лежит внутри одного сегмента с `States` $\in \{1, 2, 3\}$ и не принадлежит блоку 1. В сессии таких окон ≈ 1544 –1553, по всем 56 сессиям — **86 746**. Решение считает признаки ровно на той же сетке. Поэтому в `predict` ковариация текущего окна уже посчитана и просто берётся из памяти (§6.4).

1.5 Метрики и итоговый балл

Для каждой сессии строится матрица ошибок $G = (g_{ij})$: строки — ответы классификатора, столбцы — истинные классы, g_{ij} — число окон класса j , распознанных как i . Для каждого класса считается F1-мера и полнота:

$$F_k = \frac{2g_{kk}}{\sum_j g_{kj} + \sum_j g_{jk}}, \quad P = \frac{1}{3} \sum_{i=1}^3 \frac{g_{ii}}{\sum_k g_{ki}}, \quad F = \min_k F_k.$$

Итог по набору сессий — **невзвешенное среднее** по сессиям. Матрицы между сессиями не суммируются:

$$F_{\text{global}} = \frac{1}{N_s} \sum_s F_s, \quad P_{\text{global}} = \frac{1}{N_s} \sum_s P_s.$$

Итоговый балл из 130:

$$\text{балл} = 60 F_{\text{global}} + 30 P_{\text{global}} + \underbrace{5 + 15 F_{\text{global}}^{\text{NIRS}}}_{\text{NIRS-бонус}} + \underbrace{\leq 20}_{\text{жюри}} - \text{штрафы}.$$

Штрафы начисляются так. По каждой сессии суммируется превышение бюджета: `predict > 0.20` с, `fit_block > 1.5` с. Превышение квантуется: -1 балл за каждые 0.05 с для `predict`, за каждые 0.5 с для `fit_block`. Затем штрафы сессий суммируются, с потолком -20 и -10 соответственно. ЭЭГ-only-ответ в балл не входит. Отдельный NIRS-ответ `y_nirs` оценивается своей матрицей ошибок.

ПОЧЕМУ МЕТРИКА ОПРЕДЕЛЯЕТ УСТРОЙСТВО РЕШЕНИЯ

Худшая F1 штрафует за самый плохо распознаваемый класс. На практике это почти всегда «левая» или «правая» кисть, а не покой. Классификатор, который при сомнении отвечает «покой», получит высокую точность, но низкую min-F1. Отсюда три проектных решения:

- равные априорные вероятности классов ($1/3$, а не $0.5/0.25/0.25$);
- нормировка логитов, чтобы вероятности разных моделей были сопоставимы;
- отдельная калибровка смещений логитов, которая напрямую максимизирует min-F1 (§11).

Ориентиры «случайного» уровня:

стратегия	min-F1	macro-recall
всегда отвечать «покой»	0	0.333
угадывать пропорционально долям классов	≈ 0.25	0.333
угадывать равновероятно	≈ 0.29	0.333
пермутационный нуль на реальных сессиях (§19)	0.24–0.37	—

1.6 Ограничения

1. **Причинность** (ТЗ §3.4). Результат в момент t зависит только от сигналов до t . Запрещены двунаправленная фильтрация, нормировки по будущему и метки как признаки. Доказанная утечка обнуляет результат.
2. **Дообучение только по блокам**. После блока b разрешено использовать метки блоков $1 \dots b$. Разрешены также другие сессии и другие испытуемые — это основание для межсубъектной модели.
3. **Бюджет времени**: `predict` ≤ 0.2 с, `fit_block` ≤ 1.5 с.
4. **Деградация до ЭЭГ-only**. В двух сессиях NIRS нет, в двух он записан на 3.9 Гц вместо 12.5 Гц. Решение не должно падать и обязано использовать NIRS, когда он есть.
5. **Добровольные ограничения команды**. Первое — никаких признаков от тайминга: размеров порций `push`, пауз между вызовами, счётчиков сегментов. Почему это важно, показано в §4.4. Второе — полный датасет исследования на NITRC не используется, потому что он, вероятно, содержит закрытый тест.

2. Данные

2.1 Состав

56 сессий от 14 испытуемых: N01–N18 без N04, N05, N07, N12. У N01 3 сессии, у N14 пять, у остальных по четыре. Одна сессия — один `.mat`-файл длительностью ≈ 596 – 598 с.

ВАЖНОЕ НАБЛЮДЕНИЕ О ТЕСТЕ

В ТЗ как пример имени файла приведён `..._N04.mat`, а N04 в train нет. Скорее всего, закрытый тест содержит **новых испытуемых**. Поэтому все компоненты, обученные на других людях, оценивались строго leave-one-subject-out: для каждого испытуемого S глобальная модель переобучалась без его сессий.

2.2 ЭЭГ




- 21 канал NeoRec 21 mini, 250 Гц. Порядок колонок: c4, rpa, f8, p8, f4, p4, fp2, o2, cz, pz, fz, o1, fp1, p3, f3, p7, f7, lpa, c3, c7, c8.
- Значения — некалиброванные отсчёты АЦП с постоянной составляющей порядка 10^8 – 10^9 . Например, в первой сессии N01 первый отсчёт канала f8 равен $-6.8 \cdot 10^9$. У части каналов есть клиппинг: сигнал «залипает» на плато, у o1/o2 — до 55 % отсчётов.
- По координатам в `Montage.mat` каналы **c7/c8 лежат на позициях T7/T8** ($x \approx \pm 1, y = 0$), а не 10-10-C7/C8. lpa/rpa — преаурикулярные точки на краю монтажа.

2.3 NIRS

- 18 каналов, для каждого — концентрации HbO (оксигемоглобин) и HbR (дезоксигемоглобин). Частота 12.5 Гц; в двух сессиях 3.906 Гц. Поэтому частота в коде берётся из `meta["fs_nirs"]`.
- Колонки 0–7 лежат над правым полушарием ($x > 0$), 8–15 — симметрично над левым, 16–17 — у средней линии.
- `Frame` — индекс отсчёта ЭЭГ для каждого отсчёта NIRS. Значения повторяются: прибор выдаёт отсчёты пачками.
- В двух сессиях NIRS нет вообще.

2.4 Структура сессии

Сессия состоит из 7 блоков. Блок — 8 сегментов по 9 с в **строгом чередовании**: покой → воображение → покой → воображение... Среди четырёх сегментов воображения два «левых» и два «правых» в случайном порядке. Перед каждым сегментом идёт подготовка 1.5 с (метка 0); перед самым первым сегментом сессии — 6.5 с.

Сессия ≈ 597 с: 7 блоков**Блок 2 крупнее (≈ 84 с): 8 сегментов по 9 с, строгое чередование****Второй сегмент блока («левая») крупнее: сетка окон**

Итого 32–33 оцениваемых окна на сегмент, ≈ 258 на блок, ≈ 1549 на сессию (блоки 2–7). Концы окон — на сетке $e = 250 + 62k$ отсчётов.

Рис. 1. Временная структура. Вверху — сессия из 7 блоков. Блок 1 используется только для обучения, блоки 2–7 оцениваются. В середине — один блок: восемь 9-секундных сегментов в строгом чередовании «покой ↔ воображение», перед каждым 1.5 с подготовки. Внизу — сетка окон: окна по 1 с со сдвигом 0.248 с. Оценивается только окно, целиком лежащее внутри сегмента, поэтому первое оцениваемое окно заканчивается через 1 с после начала сегмента. В 9-секундном сегменте помещается 32–33 окна.

Следствия структуры, важные для всего дальнейшего:

- **Мало данных внутри сессии.** После блока 1 для обучения есть ≈ 258 окон (129 покой, 65 левая, 64 правая). Это всего 4 сегмента покоя и по 2 сегмента на руку. Соседние окна перекрываются на 75 % и сильно коррелированы, поэтому эффективный объём выборки ближе к числу *сегментов*, чем окон. После блока 6 окон ≈ 1550.
- **Период «покой + воображение» ≈ 21 с.** Это порядка длительности гемодинамического ответа (пик через 5–7 с, возврат за 10–15 с). Для NIRS соседние сегменты перекрываются по времени.
- **Классы строго чередуются.** Поэтому знание границы сегмента почти выдаёт класс «покой/воображение». Любой признак, зависящий от момента начала сегмента, — потенциальная утечка (§4.4).

3. Нейрофизиология: что мы ищем в сигналах

3.1 ЭЭГ: десинхронизация сенсомоторных ритмов

В покое таламокортикальные петли генерируют синхронные колебания над сенсомоторной корой:

- **μ-ритм**, 8–13 Гц;
- **β-ритм**, 13–30 Гц.

Когда соответствующий участок коры активируется, синхронность популяции нейронов разрушается и мощность ритма падает. Активация бывает при подготовке движения, при самом движении, при его кинестетическом представлении и при соматосенсорном входе. Это падение и есть **ERD** (event-related desynchronization). Для кисти эффект максимален над **контралатеральной**

моторной корой: при представлении левой руки — над C4 (правое полушарие), при представлении правой — над C3. Часто ERD двусторонний, но с контралатеральным преобладанием. Этот сигнал и различает три класса:

- **покой vs воображение** — по глубине ERD в целом;
- **левая vs правая** — по латерализации ERD.

ERD/ERS: время × частота, среднее по 56 сессиям (CAR по «чистым» каналам)




Рис. 2. Карты ERD/ERS «время × частота» на C3, Cz, C4: мощность относительно среднего покоя, среднее по 56 сессиям. При воображении любой руки мощность μ (≈ 10 Гц) и β (≈ 18 – 24 Гц) падает уже в первые секунды после начала сегмента (синий цвет). В начале сегмента покоя виден небольшой β -rebound (красный) — «отскок» β -ритма после окончания предыдущего воображения. Разница между руками — в латерализации: при левой руке ERD сильнее на C4, при правой — на C3.


Топографии μ/β (окно 0.5–9 с сегмента), среднее по сессиям

Рис. 3. Топографии μ (8–13 Гц) и β (15–30 Гц) в окне 0.5–9 с сегмента, среднее по сессиям. Правый столбец — контраст «левая – правая». Над C4 он отрицательный (при левой руке мощность ниже справа), над C3 — положительный. Это классическая контралатеральная картина, и она сосредоточена над центральными электродами.

По данным EDA ранний ERD (0.5–2.5 с сегмента) в среднем составляет -2.7 дБ. Медианный по сессиям AUC латерализации $\log P_{C3} - \log P_{C4}$ в μ -полосе для «левая vs правая» — 0.68 . Сигнал есть, но он слабый и сильно разный у разных людей.

3.2 NIRS: гемодинамический ответ

Активность нейронов через нейроваскулярное сопряжение вызывает избыточный приток крови. По учебнику в активной зоне HbO растёт, а HbR падает. Ответ начинается через 1–2 с и достигает пика через 5–7 с. При КМП он в 2–3 раза слабее, чем при реальном движении. NIRS устойчив к электрическим артефактам, но запаздывает и загрязнён системной физиологией: пульсом ~ 1 Гц, дыханием ~ 0.25 Гц, волнами Майера ~ 0.1 Гц, кожным кровотоком. Коротких каналов для удаления системной компоненты в экспорте нет.

3.3 Зачем объединять модальности

ЭЭГ быстрая и пространственно специфичная, но шумная и чувствительна к артефактам. NIRS медленный, но даёт независимую оценку «активирована ли кора» с другой физической природой шума. Литература сообщает о выигрыше гибрида на $+2...+6$ п.п. в офлайне. В исходном онлайн-исследовании гибрид ЭЭГ-only **не превзошёл**: медианная полнота 53.5 % против 57.3 %. Поэтому выигрыш от NIRS здесь нужно доказывать, а не предполагать. В финальном решении он есть: $+0.035$ min-F1, §18.4.

4. Что показал анализ данных и как это повлияло на архитектуру

Перед построением модели команда провела исследовательский анализ всех 56 сессий (research/eda/, tools/eda_figures.py). Нашлись четыре обстоятельства, которые «ломают» наивный подход. Каждое превратилось в конкретное проектное решение.

4.1 Артефакт ФЭС на ≈ 83 Гц

В исходном эксперименте правильно распознанное воображение включало стимуляцию: импульсы 70 Гц, 0.35 мс, ток нарастает на 16 мА/с. В ЭЭГ это проявилось как **узкий пик 81.5–85.5 Гц**. Он есть только в сегментах воображения и нарастает в первые 1–3 с сегмента: медиана +1.7 дБ, в трети проб больше 6 дБ. Мощность этой полосы на лучшем канале отделяет «воображение» от «покоя» с медианным AUC 0.86 по сессиям. Это оптимистичная оценка: лучший канал из 21 выбирался задним числом. Иными словами, модель, видящая частоты выше ~ 40 Гц, может научиться детектировать **стимулятор**, а не мозг. Хуже того, стимулятор включался только при правильном ответе исходного декодера, так что такая модель копировала бы старый декодер.




Рис. 4. Слева — спектр «воображение / покой»: медиана по сессиям и межквартильный размах. Единственный резкий класс-зависимый пик — около 83 Гц, далеко за границей признаков решения (35 Гц, пунктир). Справа — мощность 81.5–85.5 Гц внутри сегмента: при воображении она нарастает с ~ 0.5 с до плато к 3–4 с, что совпадает со скоростью нарастания тока стимулятора.

РЕШЕНИЕ

Все ЭЭГ-признаки берутся **только из полос ≤ 30 Гц** (запрет — всё выше 35 Гц). Полоса 83 Гц используется лишь в контрольных экспериментах как индикатор ФЭС (§19), но не в классификаторе. Отдельно проверено, что модель работает и в первые 2.5 с сегмента, пока ток ещё не вырос.

Есть тоньше проблема, которую фильтром не решить. ФЭС и вызванное ею пассивное разгибание кисти сами дают соматосенсорный μ/β -ERD, спектрально неотличимый от КМП. А ФЭС включалась именно в «удачных» пробах. Это эффект отбора, его нельзя устранить, но можно оценить (§19).

4.2 Взгляд на стрелку: горизонтальная ЭОГ

Подсказка — стрелка слева или справа от центра — видна все 9 с, и человек невольно смещает взгляд к ней. Глаз — электрический диполь, поэтому поворот взгляда даёт медленный сдвиг разности потенциалов f7–f8, то есть горизонтальную электроокулограмму. Этот признак отделяет левую руку от правой **лучше, чем физиологическая латерализация μ -ритма**:

- ГЭОГ f7–f8: медианный AUC 0.14, что эквивалентно 0.86 в обратной ориентации; эффект одного знака в 54 из 56 сессий;
- μ -латерализация C3/C4: медианный AUC всего 0.67.




Рис. 5. Разность $f7 - f8$ в полосе 0.1–3 Гц по классам с 95 % ДИ. При «правой» стрелке взгляд уходит вправо, и сигнал систематически сдвигается на весь сегмент. При «левой» сдвиг обратного знака. Это информация о направлении взгляда, а не о моторном представлении.

РЕШЕНИЕ

По умолчанию модель **не использует** $fp1$, $fp2$, $f7$, $f8$ (глаза), $o1$, $o2$ (затылок, зрительная кора, клиппинг) и lpa , gra (край монтажа). Остаётся набор $sensorimotor11 = \{c3, cz, c4, f3, fz, f4, p3, pz, p4, T7, T8\}$. Нижняя граница полос — 4 Гц, а медленный ГЭОГ-сдвиг лежит ниже 3 Гц. Вклад «подозрительных» каналов измерен отдельно: с ними $+0.026 \text{ min-F1}$ (§19, §21). Решение о них оставлено за командой, выбран консервативный вариант.

4.3 NIRS ведёт себя «наоборот»

Относительно 2 с до начала сегмента HbO при воображении **падает**, а при покое **растёт**; HbR ведёт себя зеркально. Разметка колонок при этом верна: у HbO сильнее кардиальный пик, как и должно быть. Руки NIRS различает плохо: AUC «левая/правая» 0.55–0.58.




Рис. 6. Grand average HbO/HbR по полушариям и классам: 52 сессии с частотой 12.5 Гц, базлайн –2...0 с, в единицах SD канала. Покой и воображение расходятся через 4–6 с после начала сегмента в противоположных «учебнику» направлениях. Кривые левой и правой руки почти совпадают.

Вероятные причины, не исключающие друг друга:

- **Строгое чередование с периодом ~21 с.** Базлайн воображения — это конец покоя, а базлайн покоя — конец воображения. При длинном ответе «реакция на воображение» проявляется в следующем покое.
- **Инверсная оксигенация**, описанная в fNIRS-исследованиях КМП.
- **Системные и кожные ответы** на электростимуляцию.

РЕШЕНИЕ

Знак NIRS-признаков **не фиксируется** (нет правила «рост HbO = воображение»): его выучивает классификатор. NIRS используется в основном для различения «покой/воображение», где он силён, и получает меньший вес при слиянии (0.2). Честная оговорка: NIRS может различать покой и воображение в значительной мере по фазе цикла чередования, а не по корковой активации.

4.4 Скрытая утечка через тайминг в исходном MVP

Каркас вызывает `predict` только на оцениваемых окнах. Между сегментами есть пауза ≥ 1.5 с без вызовов. В исходном MVP сглаживание вероятностей было экспоненциальным **по реальному времени**:

$$\bar{p}_t = a \bar{p}_{t_{\text{prev}}} + (1 - a) p_t, \quad a = \exp\left(-\frac{t - t_{\text{prev}}}{\tau f_s}\right).$$

На паузе между сегментами $t - t_{\text{prev}}$ велико, $a \rightarrow 0$, и сглаживание «сбрасывается». Модель тем самым узнаёт, что начался новый сегмент. При строгом чередовании граница почти выдаёт класс. Цена этой утечки — **0.053 min-F1**: при переходе на сглаживание по числу вызовов качество MVP падает с 0.472 до 0.419 (эксперимент E01_b1fix).

Второй источник — время отсчётов NIRS, которое в MVP назначалось от концов порций `push`. При другой нарезке данных на порции ответы менялись: 10 из 1549 ответов `y` и 22 ответа `y_nirs` в тесте инвариантности (§16).

РЕШЕНИЕ

Ни один признак и ни одно состояние декодера не зависят от моментов и частоты вызовов:

- ковариации считаются на фиксированной сетке отсчётов;
- NIRS индексируется номером отсчёта;
- сглаживание, если включено, идёт по числу вызовов, а в финале выключено вовсе.

Это проверяется автоматическим тестом на всех 56 сессиях.

4.5 Сводка: находка → проектное решение

находка EDA	риск	что сделано в решении	где
пик ФЭС ≈ 83 Гц только при воображении	модель детектирует стимулятор	полосы ЭЭГ только 4–30 Гц; ФЭС — лишь в контролях	§6.3, §19
ФЭС сама вызывает ERD, включалась в «удачных» пробах	переоценка качества	анализ ранних окон (до ФЭС), стратификация проб	§19
взгляд на стрелку, ГЭОГ f7–f8	модель декодирует взгляд	исключены fp1/fp2/f7/f8/o1/o2; полосы ≥ 4 Гц; контрольный ГЭОГ-декодер	§6.5, §19
клиппинг и шумные каналы	порча общего референса	детектор плохих каналов по прошлым данным; исключение из CAR	§6.6
DC $\sim 10^9$, дрейф	потеря точности, переходные процессы	вычитание 1-го отсчёта, ВЧ 0.5 Гц с установившимся начальным состоянием	§6.1–6.2
NIRS инвертирован, слабо латерализован	неверный знак признаков	знак выучивается; вес NIRS 0.2	§9, §10
чередование классов, паузы без вызовов	утечка через тайминг	признаки на сетке отсчётов; сглаживание выключено	§12, §16
тест — новые испытуемые	переоценка при оценке «на своих»	LOSO для всех глобальных компонентов	§17
мало данных в ранних блоках	плохое качество в блоках 2–3	межсубъектная модель с перецентрированием	§8.6

ЧАСТЬ II

Как устроено решение

5. Архитектура целиком

5.1 Поток данных




Рис. 7. Архитектура декодера `hbci.HybridDecoder`. В `push` сигналы фильтруются причинно и сразу сжимаются: для ЭЭГ до ковариационных матриц в точках сетки окон, для NIRS до накопленных сумм. В `fit_block` по прошлым данным и меткам завершённых блоков пересчитываются все обучаемые части. `predict` только применяет уже обученное к текущему окну, поэтому он быстрый (≈ 1 мс). Офлайн-компоненты (межсубъектная модель, вес слияния) загружаются один раз в `load`.

Устройство держится на трёх принципах.

1. **Вся дорогая работа — в `push` и `fit_block`, а не в `predict`.** Ковариации окон считаются по мере поступления данных, один раз для каждой точки сетки, и хранятся. В `predict` остаётся несколько матричных операций над одним окном.
2. **Состояние меняется только в `fit_block`.** Между блоками все центры, маски, модели и смещения заморожены. Ответ в момент t — детерминированная функция данных до t и меток завершённых блоков.
3. **Ничего не зависит от того, как и когда вызываются методы.** Фильтры с сохранённым состоянием дают побитово одинаковый результат при любой нарезке на порции. Признаки считаются на фиксированной сетке отсчётов. NIRS индексируется номером отсчёта, а не временем прихода.

5.2 Модули

файл	что внутри	роль
<code>solution/classifier.py</code>	<code>OnlineClassifier</code>	тонкая обёртка по контракту T3; всё делегирует <code>HybridDecoder</code>
<code>hbci/pipeline.py</code>	<code>HybridDecoder</code>	оркестрация <code>push</code> / <code>fit_block</code> / <code>predict</code> ; смесь моделей; LOBO-калибровка
<code>hbci/filters.py</code>	<code>StreamingSOS</code> , <code>FilterBank</code> , <code>StreamingEMA</code>	причинные IIR-фильтры с сохранённым состоянием
<code>hbci/eeg.py</code>	<code>EEGFrontEnd</code> , <code>spatial_matrix</code> , <code>transform</code>	ВЧ + банк полос, ковариации на сетке, детектор плохих каналов, матрица референса M
<code>hbci/riemann.py</code>	<code>OAS</code> , <code>Ledoit-Wolf</code> , <code>logm</code> / <code>expm</code> / <code>sqrtm</code> , средние, касательное пространство	вся риманова геометрия на <code>pumpy</code> (<code>eigh</code>), без <code>pyRiemann</code> в рантайме
<code>hbci/models.py</code>	<code>LinearModel</code> , <code>fit_linear</code> , <code>TSMModel</code> , <code>MDMMModel</code> , <code>CSP</code> , <code>GlobalEEG</code>	обучение через <code>scikit-learn</code> , предсказание — чистый <code>pumpy</code>
<code>hbci/nirs.py</code>	<code>NIRSFrontEnd</code>	фильтр NIRS, синхронизация по числу отсчётов, наклоны и уровни с лагами
<code>hbci/fusion.py</code>	<code>fuse</code> , <code>min_f1_many</code> , <code>calibrate_bias</code>	слияние модальностей; подбор смещений под <code>min-F1</code>
<code>hbci/smoothing.py</code>	<code>CalEMA</code> , <code>ema_sequence</code>	сглаживание по числу вызовов (в финале выключено)
<code>hbci/config.py</code>	<code>DEFAULTS</code> , <code>CHANNEL_SETS</code> , <code>PRESETS</code> , <code>Config</code>	конфигурация: код → <code>artifacts/config.json</code>
<code>solution/train.py</code>	офлайн-скрипт	обучение межсубъектной модели → <code>global_eeg.joblib</code>
<code>solution/artifacts/</code>	<code>config.json</code> , <code>global_eeg.joblib</code> (18 КБ), <code>fusion.json</code>	всё, что загружается при старте

Рантайм зависит только от `pumpy`, `scipy`, `scikit-learn` и `joblib` (Python 3.11, версии закреплены в `requirements.txt`). Модели обучаются через `scikit-learn`, но хранятся как `pumpy`-коэффициенты. Предсказание — это стандартизация, умножение на матрицу и `log-softmax`, без накладных расходов `sklearn`.

5.3 Жизненный цикл за одну сессию

1. `__init__(meta)`. Создаются фронтенды: частоты берутся из `meta`, память под ковариации выделяется по длине сессии. Если NIRS нет или его частота не задана, NIRS-ветка не создаётся.
2. `load(artifacts)`. Загружаются глобальная ЭЭГ-модель и `fusion.json`. Совместимость модели с конфигурацией проверяется: полосы, референс, тип усадки, `cov_avg_n`, список каналов. Затем идёт «прогрев»: пробное обучение LDA/LR и пробный `logm`. Так первый `fit_block` не платит за ленивую инициализацию библиотек.
3. **Блок 1**. Только `push`: данные фильтруются, ковариации накапливаются. `predict` не вызывается.
4. `fit_block(1)`. Первое обучение: около 258 окон, по 2 сегмента на каждую руку. С этого момента работают и сессионная, и глобальная модель; вес глобальной $w = 1/2$.
5. **Блоки 2...7**. На каждом оцениваемом окне вызывается `predict`. После каждого блока `fit_block` переобучает всё с нуля на всех прошедших блоках. Начиная с `fit_block(3)` добавляется калибровка смещений.

5.4 Финальная конфигурация

Конфигурация собирается как `DEFAULTS` из `hbci/config.py` плюс `artifacts/config.json`. Этот вариант выбран по LOSO-баллу из 20 кандидатов (эксперимент `E10_fusion/6_biasS`).

параметр	значение	смысл	§
<code>eeg.channels</code>	<code>sensorimotor11</code>	c3, cz, c4, f3, fz, f4, p3, pz, p4, c7 (T7), c8 (T8)	6.5
<code>eeg.reference</code>	<code>car_clean</code>	общее среднее по 13 каналам без fp1/2, f7/8, o1/2, lpa/rpa	6.5
<code>eeg.hp_hz</code>	0.5	ВЧ Баттерворт 2-го порядка	6.2
<code>eeg.bands</code>	4–8, 8–12, 12–16, 16–20, 20–24, 24–30 Гц	банк полос, Баттерворт 4-го порядка	6.3
<code>eeg.cov / cov_eps</code>	<code>oas / 10⁻⁴</code>	усадка ковариации + $\varepsilon \cdot \text{tr} \cdot \mathbf{I}$	6.8
<code>eeg.cov_avg_n</code>	5	среднее ковариаций по 5 окнам сетки (≈ 2 с прошлого)	6.7
<code>eeg.mean</code>	<code>logeuclid</code>	центр перецентрирования — лог-евклидово среднее	7.3
<code>eeg.features</code>	<code>ts+mdm</code>	касательное пространство: LDA + ближайшее среднее	8
<code>eeg.classifier</code>	<code>sllda</code>	shrinkage-LDA (lsqr, Ledoit–Wolf), априорные 1/3	8.2
<code>eeg.logit_T</code>	1	нормировка логитов: SD = 1 на обучении	8.3
<code>eeg.mdm_metric</code>	<code>logeuclid</code>	MDM в касательном пространстве (быстро)	8.4
<code>eeg.bad_channels</code>	вкл.; доля плато > 5 %, мощность > 8× медианы	детектор плохих каналов	6.6
<code>global.enabled, k</code>	да, 1	межсубъектная LR, вес $w = k/(k + n_{\text{блоков}})$	8.6–8.7
<code>global.recenter</code>	<code>all</code>	центр глобальной модели — все прошлые окна	8.6
<code>nirs.lp_hz / hp_hz</code>	0.4 / 0 (выкл.)	НЧ Баттерворт 2-го порядка, без ВЧ	9.2
<code>nirs.use_slope, slope_s</code>	да, 4 с	МНК-наклоны за 4 с	9.4
<code>nirs.lags_s</code>	0, 2, 4, 6	лаги наклонов	9.4
<code>nirs.use_level</code>	нет	уровни относительно базлайна отключены	9.4
<code>nirs.lateral</code>	да	контрасты «левое – правое полушарие» для HbO и HbR	9.4
<code>nirs.classifier, logit_T</code>	<code>sllda, 1</code>	отдельный NIRS-классификатор	9.5
<code>fusion.mode, w_eeg</code>	<code>loglinear, 0.8</code>	$\log p = 0.8 \log p_{\text{ЭЭГ}} + 0.2 \log p_{\text{NIRS}}$	10
<code>bias.mode</code>	<code>session</code>	ЛОВО-калибровка с ≥ 3 блоков, усадка $\lambda = n/(n+3)$	11
<code>smoothing.tau_s</code>	0	временное сглаживание ответов выключено	12
<code>priors</code>	1/3, 1/3, 1/3	равные априорные вероятности	8.2

6. Предобработка ЭЭГ: от отсчётов АЦП к ковариациям

Этот раздел описывает всё, что происходит с ЭЭГ до того, как появляются признаки. Код — `hbci/eeg.py` (`EEGFrontEnd.push`) и `hbci/filters.py`. Каждая операция причинна, то есть использует только уже поступившие отсчёты. Каждая инвариантна к нарезке на порции: при любом разбиении потока на куски результат побитово одинаков.




Рис. 8. Цепочка обработки ЭЭГ для одного окна. Сверху вниз: сырой сигнал 21 канала → фильтры → шесть ковариационных матриц 21×21 в точке сетки → усреднение по 5 окнам → референс и выбор каналов (11×11) → усадка → отбеливание центром сессии → матричный логарифм → 66 чисел на полосу, 396 признаков. Серым помечено, где хранится промежуточный результат.

6.1 Вычитание первого отсчёта

$$z_t = x_t - x_0.$$

Сырые значения — отсчёты АЦП с постоянной составляющей до 10^9 , а полезный сигнал на много порядков меньше. Вычитание константы x_0 , известной с первого `push`, решает две задачи.

- Фильтры работают с числами масштаба сигнала, а при возведении в квадрат (ковариации) не теряется точность `float64`.
- Первый отсчёт становится нулём, и ВЧ-фильтр стартует без огромной «ступеньки» на входе (см. следующий пункт).

Это причинная операция: используется только уже полученный отсчёт.

6.2 ВЧ-фильтр 0.5 Гц

Баттерворт 2-го порядка с частотой среза 0.5 Гц, в форме каскада биквадратных секций (SOS), `scipy.signal.sosfilt`. Он убирает медленный дрейф электродных потенциалов и остаток постоянной составляющей. Всё, что выше 4 Гц и используется в признаках, он практически не затрагивает.

Причинность и инвариантность. Внутреннее состояние фильтра z_i хранится между вызовами `push`. Рекурсия IIR-фильтра на каждом шаге зависит только от текущего входа и состояния. Поэтому фильтрация порциями по 1 отсчёту, по 62 или всем сигналом сразу даёт **побитово одинаковый** результат. Это проверено тестом (§16).

Начальное состояние. При первом вызове `zi` устанавливается в установившееся состояние для постоянного входа, равного первому отсчёту: `sosfilt_zi(sos) · z0`. После вычитания x_0 это ноль, так что фильтр стартует «как будто сигнал всегда был таким». Без этой инициализации скачок с нуля до 10^9 вызвал бы переходный процесс длиной в секунды.

6.3 Банк полосовых фильтров 4–30 Гц

Отфильтрованный сигнал параллельно проходит через шесть полосовых фильтров Баттерворта: `butter(4, [lo, hi], 'bandpass')`, то есть фильтр 8-го порядка из 4 SOS-секций. Каждый хранит своё состояние.

полоса, Гц	4–8	8–12	12–16	16–20	20–24	24–30
физиология	θ , нижняя α	μ (основной пик)	верхняя μ / нижняя β	β	β	верхняя β

Выход фронтенда — массив $(n, 6, 21)$: шесть полосовых версий всех 21 канала.

ПОЧЕМУ ИМЕННО ТАК

- **Узкие полосы по 4 Гц.** Индивидуальная частота μ -ритма у разных людей от 8 до 13 Гц, а информативная β -подполоса тоже индивидуальна. Узкие полосы позволяют линейной модели самой выбрать нужные частоты с нужными весами — это идея filter bank CSP (Ang 2012). Одна широкая полоса 8–30 Гц смешала бы их.
- **Верх — 30 Гц.** Выше начинаются артефакт ФЭС (≈ 83 Гц) и мышечная активность (ЭМГ > 20–30 Гц на височных каналах). Измерено: расширение до 40 Гц снижает min-F1 финала с 0.507 до 0.500, до 100 Гц — до 0.492, хотя AUC «покой/воображение» при 100 Гц растёт (§19). Модель с 100 Гц начинает детектировать стимулятор, но это не помогает итоговому качеству.
- **Низ — 4 Гц.** Медленный сдвиг от поворота глаз (ГЭОГ) лежит ниже 3 Гц. Полоса 4–8 Гц добавлена, потому что расширение с 8–30 до 4–30 Гц дало +0.009 min-F1 (`E03_ablations`).
- **Цена причинности.** Узкополосный IIR-фильтр 8-го порядка вносит групповую задержку ≈ 0.2 с в центре полосы и до 0.35 с у её краёв. Она одинакова при обучении и применении, поэтому не мешает классификации. Она лишь немного сдвигает момент, когда ERD становится виден.

6.4 Сетка окон и «сырые» ковариации

В каждой точке сетки $e_k = 250 + 62k$ (той же, что у окон каркаса, §1.4) для каждой полосы b берутся последние 250 отфильтрованных отсчётов $X_{k,b} \in \mathbb{R}^{250 \times 21}$ и считается

$$S_{k,b} = \frac{1}{250} X_{k,b}^\top X_{k,b} \in \mathbb{R}^{21 \times 21}.$$

Среднее не вычитается: полосовой сигнал имеет нулевое среднее, поэтому S — оценка ковариации. Чтобы окна на стыке порций считались правильно, фронтенд держит «хвост» из последних 250 отфильтрованных отсчётов. Точки сетки определены абсолютным номером отсчёта, поэтому набор окон не зависит от того, как данные нарезаны на порции.

Хранится массив S формы $(K, 6, 21, 21)$, где $K \approx 2400$ окон на сессию. Это ≈ 51 МБ в float64.

ПОЧЕМУ ХРАНИТЬ КОВАРИАЦИИ ВСЕХ 21 КАНАЛА, А НЕ СИГНАЛ И НЕ ПРИЗНАКИ

Всё, что происходит дальше, — функции ковариационной матрицы. Выбор каналов, референс, усреднение по окнам, центр сессии — всё выражается через S . Поэтому достаточно посчитать S один раз на точку сетки. Ковариации хранятся по **всем** 21 каналам, потому что маска плохих каналов и референс могут меняться после каждого блока. Для линейного преобразования $y = Mz$ ковариация пересчитывается точно:

$$\text{cov}(Mz) = M S M^T,$$

и перефильтровывать сигнал не нужно. Бонус: в `predict` ковариация текущего окна уже лежит в памяти, потому что каркас вызывает `predict` ровно в точках сетки.

6.5 Референс и выбор каналов: матрица M

Пространственная обработка — одна матрица $M \in \mathbb{R}^{p \times 21}$, где $p = 11$ выходных каналов:

$$C'_{k,b} = M S_{k,b} M^T \in \mathbb{R}^{11 \times 11}.$$

Строка M для выходного канала c при референсе «общее среднее по чистым каналам» (`car_clean`):

$$M_{c,\cdot} = e_c - \frac{1}{|Q|} \sum_{q \in Q} e_q,$$

где e_c — единичный вектор канала, а Q — «чистые» каналы: все 21 без `fp1`, `fp2`, `f7`, `f8`, `lpa`, `gra`, `o1`, `o2` и без каналов, признанных плохими. Обычно $|Q| = 13$. Например, строка для `c3` — это $+0.923$ на `c3` и -0.077 на каждом из остальных 12 чистых каналов.

Выходные каналы (`sensorimotor11`): **`c3`, `cz`, `c4`, `f3`, `fz`, `f4`, `p3`, `pz`, `p4`, `c7` (T7), `c8` (T8)**. `p7` и `p8` входят в референс, но не в выход. Это не случайность: если бы выходом были все каналы референса, их сумма после CAR была бы тождественно нулевой и матрица 11×11 оказалась бы вырожденной.

ПОЧЕМУ ТАКИЕ КАНАЛЫ И ТАКОЙ РЕФЕРЕНС

- **Сенсомоторные каналы** покрывают моторную и соматосенсорную кору обоих полушарий. КМП даёт ERD именно здесь.
- **T7/T8** (`c7/c8`) полезны: без них (`sensorimotor9`) `min-F1` финала падает с 0.507 до 0.500, в сессионном варианте — с 0.452 до 0.434.
- **Исключение лобных и затылочных каналов** — защита от ГЭОГ и зрительной α -активности (§4.2).
- **Общее среднее только по чистым каналам**. Если бы в референс вошёл `fp1` с глазными артефактами или `o1` с клиппингом, артефакт через референс попал бы во все каналы.
- **Вариант референса почти не важен для качества**: без референса 0.449, CAR 0.452, малый лапласиан 0.451 (`E04_riemann`, сессионная оценка). CAR выбран как самый простой и устойчивый к плохим каналам.

6.6 Детектор плохих каналов

Вызывается в каждом `fit_block` по **всем прошлым данным**, поэтому маска фиксирована между блоками. Канал считается плохим, если выполнено любое из условий.

1. **Клиппинг или обрыв**: доля «плоских» отсчётов ($x_t = x_{t-1}$ в сыром сигнале) больше 5 %. Счётчик ведётся непрерывно в `push`.

2. **Шумный контакт:** медианная по окнам лог-мощность канала в 4–30 Гц выше медианы по всем каналам больше чем в 8 раз: $v_c = \text{med}_k \log \sum_b S_{k,b,cc}$, $d_c = v_c - \text{med}_c v_c$, условие $d_c > \ln 8$.

3. **«Мёртвый» канал:** $d_c < -\ln 400$.

Что происходит с плохим каналом:

- в **сессионной модели** он исключается и из референса, и из выхода. Размерность уменьшается: 10 каналов дают 55 признаков на полосу;
- в **глобальной модели** он заменяется средним хороших соседей (например, $c3 \leftarrow f3, p3, T7, cz$). Размерность сохраняется, потому что у глобальной логистической регрессии фиксированный вход 396.

КАК ВЫБИРАЛИ КРИТЕРИЙ

Критерий из ТЗ « $|x| > 0.99 \cdot \max$ » на этих данных не работает: из-за дрейфа постоянной составляющей максимум нерепрезентативен, а клиппинг проявляется как плато. У 01/02 плато занимают до 55 % отсчётов. Робастный z-score по MAD тоже отвергнут: при 11 каналах MAD мал, и помечались просто «тихие» каналы (0.4–0.8× медианы). Итоговый детектор нашёл шумные каналы в 11 сессиях из 56 (p4, pz, c8, c7, c4...), с мощностью в 13–137 раз выше медианы. Если плохим признан c3 или c4, в журнал пишется предупреждение.

6.7 Усреднение ковариаций по 5 окнам сетки

$$\bar{S}_{k,b} = \frac{1}{5} \sum_{j=0}^4 S_{k-j,b}.$$

Усреднённая оценка покрывает отрезок $[e_k - 250 - 4 \cdot 62, e_k]$, то есть 498 отсчётов ≈ 2 с **прошлого** сигнала. Используются только уже прошедшие окна на той же фиксированной сетке, и от моментов вызовов это не зависит. Усреднение применяется везде одинаково: в обучении, в `predict`, в центре сессии и в `train.py`.

ЗАЧЕМ ЭТО НУЖНО: ОЦЕНКА КОВАРИАЦИИ ПО ОДНОЙ СЕКУНДЕ ОЧЕНЬ ШУМНАЯ

Сигнал в полосе шириной $W = 4$ Гц за $T = 1$ с несёт порядка $2WT \approx 8$ независимых отсчётов, хотя формально их 250 (соседние отсчёты узкополосного сигнала сильно коррелированы). Оценивать по ним матрицу 11×11 , то есть 66 параметров, — задача сильно недоопределённая. Усреднение по 2 с примерно удваивает эффективный объём. Эффект виден по качеству. В сессионном варианте (`E06_smoothing`) AUC «левая/правая» растёт с 0.611 ($n = 1$) до 0.627 ($n = 5$), AUC «покой/воображение» — с 0.785 до 0.797.

Почему именно 5, а не 8, хотя при $n = 8$ AUC ещё выше (0.637)? При $n = 8$ min-F1 уже падает. Вероятное объяснение — геометрия протокола. Первое оцениваемое окно сегмента заканчивается через 1 с после его начала. При $n = 5$ самое раннее из усредняемых окон начинается за ≈ 1 с до начала сегмента, внутри 1.5-секундной подготовки. Поэтому усреднение **никогда не захватывает предыдущий сегмент другого класса**. При $n = 8$ оно уходит на 1.74 с назад и в начале сегмента смешивает текущий класс с предыдущим.

6.8 Усадка OAS и регуляризация

Выборочная ковариация S (после M и усреднения, размер $p = 11$) сжимается к масштабированной единичной матрице по формуле Oracle Approximating Shrinkage (Chen et al., 2010). Реализация — `riemann.shrink_oas`, эквивалент `sklearn.covariance.oas`:

$$\mu = \frac{\text{tr } S}{p}, \quad \alpha = \frac{1}{p^2} \sum_{ij} S_{ij}^2, \quad \rho = \min\left(1, \frac{\alpha + \mu^2}{(n+1)(\alpha - \mu^2/p)}\right), \quad \hat{C} = (1 - \rho)S + \rho\mu I,$$

где $n = 250$. Затем добавляется малая регуляризация, гарантирующая положительную определённость:

$$C = \hat{C} + \varepsilon \frac{\text{tr } \hat{C}}{p} I, \quad \varepsilon = 10^{-4}.$$

Зачем. Следующий шаг — матричный логарифм, а он очень чувствителен к малым собственным числам: $\log \lambda \rightarrow -\infty$ при $\lambda \rightarrow 0$. У выборочной ковариации по малому числу эффективных отсчётов малые собственные числа систематически занижены, а большие завышены. Усадка стягивает спектр к среднему, и логарифм становится устойчивым. Выбор между OAS и Ledoit–Wolf на качество не влияет: 0.4521 и 0.4523 (E04_riemann).

7. Признаки ЭЭГ: риманова геометрия ковариаций

После предобработки каждое окно описывается шестью ковариационными матрицами $C_b \in \mathbb{R}^{11 \times 11}$, по одной на полосу. Этот раздел объясняет, как из них получаются 396 чисел, на которых работают классификаторы, и почему именно так. Код — `hbci/riemann.py`, `HybridDecoder._session_inputs`, `pipeline.ts_vector`.

7.1 Почему ковариационная матрица — правильное описание окна

Пусть $y(t) \in \mathbb{R}^{11}$ — полосовой сигнал 11 каналов в окне. Его ковариация $C = \mathbb{E}[y y^\top]$ содержит:

- **на диагонали** — мощность ритма в данной полосе на каждом электроде. Именно её уменьшает ERD: при представлении левой руки падает μ -мощность на C4;
- **вне диагонали** — совместную изменчивость каналов. После общего референса локальная десинхронизация под C3 меняет не только мощность C3, но и её корреляцию с соседями. В этом тоже есть пространственная информация о том, где произошла десинхронизация.

Классические признаки моторного воображения — функции от C . Лог-мощность канала — это $\log C_{ii}$. Мощность CSP-компоненты — $w^\top C w$. Лапласиан — $m^\top C m$. Значит, C содержит всю информацию второго порядка, которую используют эти методы. Остаётся вопрос, как правильно превратить матрицу в вектор для линейного классификатора. Римановы методы (Barachant et al., 2012; Congedo et al., 2017) — один из самых надёжных ответов при малом объёме данных. В бенчмарке MOABB на 36 датасетах они не уступают глубоким сетям (Chevallier et al., 2024).

7.2 Почему нельзя просто взять элементы матрицы

Ковариационные матрицы симметричны и положительно определены (SPD). Они образуют не векторное пространство, а конус:

- разность двух SPD-матриц может не быть SPD;
- обычное среднее «раздувается» окнами с большой мощностью;
- изменения мощности мультипликативны: ERD −3 дБ — это умножение на 0.5, а не вычитание константы.

Естественная мера расстояния на этом множестве — аффинно-инвариантная риманова метрика:

$$\delta(A, B) = \left\| \log(A^{-1/2} B A^{-1/2}) \right\|_F = \sqrt{\sum_i \log^2 \lambda_i(A^{-1} B)}.$$

У неё два ключевых свойства.

1. **Логарифм делает мультипликативные изменения аддитивными.** Уменьшение мощности вдвое — это сдвиг на $\ln 2$ независимо от исходного уровня мощности.
2. **Инвариантность к линейному смешиванию:** $\delta(WAW^T, WBW^T) = \delta(A, B)$ для любой обратимой W . Коэффициенты усиления электродов, импеданс и объёмное проведение — это как раз линейные смешивания, и на расстояния между окнами они не влияют.




Рис. 9. Идея касательного пространства. Ковариационные матрицы окон лежат на искривлённом многообразии SPD-матриц. В точке-центре сессии C_{ref} строится касательная плоскость, и каждая матрица отображается на неё логарифмическим отображением. Около центра евклидовы расстояния на плоскости почти совпадают с римановыми, поэтому на векторах можно применять обычные линейные классификаторы. Классы (покой, левая, правая) образуют на плоскости облака, разделимые гиперплоскостями.

7.3 Перецентрирование: центр сессии

Для каждой полосы вычисляется центр — **лог-евклидово среднее ковариаций всех прошлых окон сессии**:

$$C_{\text{ref}} = \exp\left(\frac{1}{N} \sum_{k=1}^N \log C_k\right),$$

где сумма берётся по *всем* окнам сетки, полученным к моменту `fit_block`. Сюда входят окна подготовки, покоя и воображения, и **меток центр не использует**. Затем каждая матрица «отбеливается» центром:

$$\tilde{C} = C_{\text{ref}}^{-1/2} C C_{\text{ref}}^{-1/2}.$$

После этого типичное окно сессии соответствует единичной матрице I . Из-за аффинной инвариантности отбеливание не меняет расстояний между окнами. Оно лишь переносит точку отсчёта в I , где логарифм даёт хорошую локальную линеаризацию.

ПОЧЕМУ ЭТО ТАК ВАЖНО

- **Внутри сессии.** Признаки описывают *отклонения* от среднего состояния этого человека в этот день, а не абсолютную мощность. Абсолютная мощность зависит от импеданса электродов, толщины черепа и индивидуальной амплитуды ритма.
- **Между сессиями и людьми.** Если каждую сессию отбелить её собственным центром, средние состояния всех людей совпадут в точке I . Индивидуальные различия в первом приближении исчезают, а направления, связанные с классами (ERD над C3 или C4), у разных людей похожи. Это основа межсубъектного переноса (Zanini et al., 2018; §8.6).
- **Честность.** Центр строится без меток и только по прошлому. Он пересчитывается в каждом `fit_block` и фиксирован между блоками.

Реализация. Логарифмировать все ≈ 2400 окон $\times 6$ полос в каждом `fit_block` дорого. Поэтому сумма $\sum_k \log C_k$ кэшируется для данной матрицы M , и в каждом `fit_block` логарифмируются только новые окна (≈ 340 за блок). Если маска плохих каналов изменилась, у M меняется ключ кэша, и сумма пересчитывается. Лог-евклидово среднее выбрано вместо итерационного среднего Карчера, потому что считается в замкнутой форме и инкрементально, а по качеству они равны: 0.4521 и 0.4517 (E04_riemann).

7.4 Касательный вектор

Матричный логарифм отбеленной матрицы считается через собственное разложение:

$$\tilde{C} = V \operatorname{diag}(\lambda_1, \dots, \lambda_p) V^\top \Rightarrow L = \log \tilde{C} = V \operatorname{diag}(\log \lambda_1, \dots, \log \lambda_p) V^\top.$$

L симметрична, поэтому достаточно верхнего треугольника. Вектор признаков полосы:

$$t = (L_{11}, \dots, L_{pp}; \sqrt{2} L_{12}, \sqrt{2} L_{13}, \dots, \sqrt{2} L_{p-1,p}) \in \mathbb{R}^{p(p+1)/2}.$$

Множитель $\sqrt{2}$ стоит потому, что каждый внедиагональный элемент встречается в симметричной матрице дважды. С ним $\|t\|_2^2 = \|L\|_F^2 = \delta^2(C, C_{\text{ref}})$: евклидова длина вектора равна риманову расстоянию до центра. Поэтому евклидовы методы (LDA, логистическая регрессия, ближайшее среднее) на t согласованы с геометрией многообразия.

При $p = 11$ получается $11 \cdot 12/2 = 66$ чисел на полосу. Шесть полос конкатенируются в **396 признаков**.

7.5 Что эти числа означают физиологически

Если бы $\tilde{C}$ была диагональной, то $L_{ii} = \log(P_i/P_{\text{ref},i})$ — натуральный логарифм отношения мощности на электроде i к её типичному уровню в сессии. Это в точности ERD в логарифмических единицах: -2.7 дБ ≈ -0.62 в натуральных логарифмах. В общем случае диагональ L — это «логарифмические ERD-карты» по полосам, а внедиагональные элементы описывают, как изменились связи между каналами.

Линейный классификатор на t — взвешенная сумма логарифмов мощностей и связей по всем полосам. Фактически он сам строит пространственно-частотный фильтр, как FBCSP, но задача обучения выпуклая, решение устойчивое, и оно не зависит от случайно «удачного» CSP-фильтра. Сравнение подтверждает это: воспроизведённый пайплайн авторов исследования (FB-CSP + sLDA) даёт min-F1 ЭЭГ 0.38–0.40, касательное пространство + sLDA — 0.42 (§20).

7.6 Размерности по шагам

шаг	объект	размер на окно	где
сырой сигнал	250 отсчётов × 21 канал	250 × 21	push
банк полос	6 полосовых версий	250 × 6 × 21	FilterBank
ковариации в точке сетки	$S_{k,b}$	6 × 21 × 21	EEGFrontEnd.S
среднее по 5 окнам	$\bar{S}_{k,b}$	6 × 21 × 21	_S
референс + выбор каналов	$M \bar{S} M^T$	6 × 11 × 11	transform
усадка	C_b (OAS + ϵI)	6 × 11 × 11	estimate_cov
отбеливание	$\tilde{C}_b$	6 × 11 × 11	cref_isqrt @ C @ cref_isqrt
логарифм + верхний треугольник	t_b	6 × 66	ts_vector
вектор признаков	t	396	вход LDA, MDM, глобальной LR

Вычислительно всё сводится к пакетным `numpy.linalg.eigh` для матриц 11×11. Для устойчивости собственные числа ограничиваются снизу: $\max(\lambda, 10^{-12} \lambda_{\max})$. В `predict` это 6 разложений для сессионной модели и 6 для глобальной — доли миллисекунды.

8. Классификаторы ЭЭГ

На векторе $t \in \mathbb{R}^{396}$ работают три модели. Две сессионные (shrinkage-LDA и «ближайшее среднее») обучаются в каждом `fit_block` на прошедших блоках текущей сессии. Одна глобальная (логистическая регрессия) обучена заранее на других людях. Их лог-вероятности смешиваются в одну оценку $\log p_{\text{ЭЭГ}}$. Код — `hbci/models.py`, `HybridDecoder._fit_session`, `_session_logp`, `_global_logp`, `_mix`.




Рис. 10. Как из признаков получается ответ. Сессионные LDA и MDM усредняются в лог-пространстве. Затем они смешиваются с глобальной моделью с весом, убывающим по мере накопления данных сессии. Потом идёт лог-линейное слияние с NIRS (§10). В конце к логитам прибавляются откалиброванные смещения (§11) и берётся `argmax`. Параллельно по той же схеме выдаются отдельные ответы `y_eeg` и `y_nirs`.

8.1 Обучающая выборка сессионных моделей

В `fit_block` метки завершённого блока превращаются в список обучающих окон (`_add_labels`). Берутся все точки сетки e_k , окно $[e_k - 250, e_k)$ которых целиком лежит внутри одного сегмента с меткой 1, 2 или 3. Это те же окна, что оценивает каркас, но включая блок 1. Накапливаются окна всех прошедших блоков.

после блока	1	2	3	4	5	6
окон для обучения (покой / левая / правая)	258 (129/65/64)	517	773	1031	1289	1548 (773/390/385)

Пример сессии 2025.12.04_N01; в других сессиях числа отличаются на единицы.

Признаки стандартизируются по обучающим окнам: $z = (t - \mu)/\sigma$, где μ, σ — поэлементные среднее и SD. Параметр «пропускать начало сегмента при обучении» (`train_skip_s`) проверен и отвергнут: пропуск 0.5 с снижает min-F1 с 0.452 до 0.449, пропуск 1 с — до 0.446. Ранние окна содержат полезный ERD.

8.2 Shrinkage-LDA

Линейный дискриминантный анализ предполагает, что признаки каждого класса распределены нормально с общей ковариационной матрицей Σ и своими средними m_k . Тогда апостериорная лог-вероятность класса линейна по z :

$$\log p(k | z) = z^\top \Sigma^{-1} m_k - \frac{1}{2} m_k^\top \Sigma^{-1} m_k + \log \pi_k - \log Z(z).$$

Ковариация оценивается с усадкой Ледуа–Вольфа, коэффициент усадки γ вычисляется аналитически:

$$\hat{\Sigma} = (1 - \gamma) S_w + \gamma \nu I.$$

Реализация: `LinearDiscriminantAnalysis(solver="lsqr", shrinkage="auto", priors=[1/3, 1/3, 1/3])`. После обучения сохраняются только $W \in \mathbb{R}^{3 \times 396}$ и $b \in \mathbb{R}^3$. Предсказание — $\log p = \log \text{softmax}(Wz + b)$ на чистом numpy.

ПОЧЕМУ SHRINKAGE-LDA

- **Признаков больше, чем окон.** После блока 1 окон ≈ 258 , а признаков 396, так что обычная LDA вырождена. Усадка делает задачу корректной при любом соотношении. При этом эффективное число независимых наблюдений ещё меньше — порядка числа сегментов.
- **Байес-оптимальность.** Для гауссовых классов с общей ковариацией LDA — оптимальный классификатор, а ERD-признаки в лог-пространстве близки к гауссовым.
- **Проверено сравнением.** Логистическая регрессия на тех же признаках ранжирует чуть лучше (AUC 0.81–0.83 против 0.785), но её `argmax`-решения хуже: min-F1 0.420–0.428 против 0.452 у sLDA (`E04_riemann`). sLDA — стандарт в ИМК (Blankertz et al., 2011; Lotte et al., 2018).
- **Равные априорные вероятности** (1/3), а не доли классов (0.5/0.25/0.25). Метрика — худшая F1 и `macro-recall`, то есть классы равноправны. Априорная вероятность 0.5 для покоя сдвинула бы решения в пользу покоя за счёт рук.

8.3 Нормировка логитов (temperature scaling)

Это одна из ключевых деталей решения. Анализ сохранённых вероятностей показал, что sLDA на ~400 признаках при нескольких сотнях окон **сверхуверен**: лог-вероятности проигравших классов достигали −65...−118. Такая модель при смешивании с глобальной моделью, MDM и NIRS решает всё одна. Калибровка смещений в диапазоне ± 1.5 тогда ничего не меняет.

Поэтому после обучения логиты нормируются по обучающей выборке (`models._norm_logits`):

$$Z = Wz_i + b \text{ (по всем обучающим окнам),} \quad Z_{ik}^c = Z_{ik} - \frac{1}{3} \sum_j Z_{ij}, \quad s = \text{SD}(Z^c),$$

$$W \leftarrow \frac{W}{sT}, \quad b \leftarrow \frac{b}{sT}, \quad T = 1.$$

Деление на положительное число не меняет ни argmax , ни ранжирования. Меняется только «уверенность»: центрированные логиты на обучении получают единичный разброс. Это аналог *temperature scaling*. Та же нормировка применяется к NIRS-модели.

вариант (LOSO, E10_fusion)	F_{global}	P_{global}
без нормировки (лучший вес глобальной модели, $k = 4$)	0.4810	0.6153
$T = 0.5, k = 1$	0.4945	0.6307
$T = 1, k = 1$	0.5039	0.6414
$T = 2, k = 4$	0.4830	0.6254

Прирост **+0.023 min-F1** — второй по величине вклад после межсубъектного переноса.

8.4 MDM в касательном пространстве

Второй сессионный классификатор — «минимальное расстояние до среднего» (Minimum Distance to Mean). Для каждого класса запоминается центроид — среднее касательных векторов его обучающих окон:

$$g_k = \frac{1}{N_k} \sum_{i: y_i=k} t_i, \quad d_k^2(t) = \|t - g_k\|^2.$$

Лог-вероятности — softmax от отрицательных расстояний с температурой:

$$\log p_{\text{MDM}}(k | t) = \log_{\text{softmax}_k}(-d_k^2(t)/T),$$

где T — медиана по обучающим окнам положительных величин $d_k^2 - \min_j d_j^2$. Так «типичная» разница расстояний даёт логит порядка 1, и масштаб согласован с нормированным LDA. В примере сессии $T \approx 7$.

Это MDM с лог-евклидовой метрикой в точке C_{ref} : $\|t - g_k\|$ — лог-евклидово расстояние между отбеленными матрицами.

ЗАЧЕМ ВТОРОЙ КЛАССИФИКАТОР И ПОЧЕМУ ЛОГ-ЕВКЛИДОВА МЕТРИКА

- **MDM устойчив при малом числе данных.** Он оценивает только три средних, без ковариации признаков. MDM лучше всех ранжирует: AUC 0.85–0.87 для «покой/воображение» и 0.63–0.65 для «левая/правая» в сессионной оценке. Откалиброван он хуже (min-F1 одного MDM 0.39–0.40), но в ансамбле с LDA дополняет его. LDA взвешивает направления через Σ^{-1} , MDM смотрит на «сырую» геометрию. Итог: 0.4891 без MDM против 0.5039 с ним (+0.015, E10_fusion/G_tsonly).
- **Лог-евклидова метрика вместо римановой** выбрана из-за бюджета времени. MDM с римановым расстоянием требует собственных разложений на каждое расстояние, в том числе при каждом из LOBO-переобучений (§11). `fit_block` доходил до 2.47 с — это штраф. Лог-евклидов вариант переиспользует уже посчитанные векторы t : `fit_block` сократился до 0.58 с при том же качестве.

8.5 Сессионный ансамбль

$$\log p_s = \log_{\text{softmax}}\left(\frac{1}{2}(\log p_{\text{LDA}} + \log p_{\text{MDM}})\right).$$

Усреднение в лог-пространстве — геометрическое среднее вероятностей. Класс побеждает, только если обе модели дают ему заметную вероятность. Это даёт более «осторожное» решение, чем арифметическое среднее.

8.6 Глобальная (межсубъектная) модель

Главная трудность задачи — ранние блоки. После блока 1 у сессионной модели всего по два 9-секундных сегмента на руку. Глобальная модель — это готовое знание о том, как ERD выглядит у людей вообще. Она обучается офлайн скриптом `solution/train.py`; при проверке он не запускается, результат лежит в `artifacts/global_eeg.joblib`.

Обучение (`train.py`), для каждой из 56 сессий `train`:

1. Сессия прогоняется через **тот же причинный** EEGFrontEnd, что и онлайн: вычитание x_0 , ВЧ, банк полос, ковариации на сетке. Никакой двунаправленной фильтрации.
2. Плохие каналы определяются по данным блока 1, как онлайн при первом `fit_block`, и **интерполируются** соседями. Так размерность у всех сессий одинакова — 11 каналов.
3. Ковариации усредняются по 5 окнам, проходят через M (CAR + 11 каналов) и усадку OAS.
4. Центр C_{ref} сессии — лог-евклидово среднее окон **блока 1**, как онлайн после первого `fit_block`.
5. Касательные векторы (396) считаются для всех размеченных окон всех 7 блоков.

Затем окна всех сессий объединяются: **101 194 окна**, 14 испытуемых. Признаки стандартизуются, и обучается мультиномиальная логистическая регрессия `LogisticRegression(C=0.1, class_weight="balanced")`. Сохраняются $\mu, \sigma, W \in \mathbb{R}^{3 \times 396}, b$ и метаданные: конфигурация, список файлов, версии библиотек. Всего 18 КБ.

Для честной оценки тот же скрипт в режиме `--mode loso` строит 14 моделей, каждую без одного испытуемого. Тест `test_artifacts_loso.py` проверяет, что модель испытуемого S не видела его сессий.

Применение онлайн. В первом `fit_block` строится матрица $M_{\text{глоб}}$ с интерполяцией плохих каналов и дальше не меняется. Центр для глобальной модели **пересчитывается в каждом `fit_block` по всем прошлым окнам** (`recenter = "all"`, адаптивное перецентрирование). Это дало +0.004 min-F1 (0.4772 → 0.4810) по сравнению с центром только по блоку 1. Признаки считаются так же, как в §7, и подаются в сохранённую линейную модель.

ПОЧЕМУ ПЕРЕНОС МЕЖДУ ЛЮДЬМИ ВООБЩЕ РАБОТАЕТ

У каждого человека свои абсолютные мощности ритмов, импедансы электродов и геометрия головы. Без выравнивания признаки разных людей несопоставимы. Отбеливание собственным центром сессии переносит «среднее состояние» каждого человека в одну точку — единичную матрицу. После этого одинаковые физиологические события одинаково выглядят в касательном пространстве: « μ -мощность на C4 упала относительно обычного уровня» — это одна и та же координата у всех. Это метод Riemannian re-centering (Zanini et al., 2018), родственник Euclidean Alignment (He & Wu, 2020).

Эффект измерен на новых испытуемых (LOSO, `E08_transfer`). Глобальная модель **одна** ранжирует лучше сессионной: AUC «покой/воображение» 0.821 против 0.799, «левая/правая» 0.650 против 0.636. Но её `argmax` откалиброван плохо (min-F1 0.389): у нового человека порог «покой/воображение» смещён. Поэтому она используется в смеси, а не сама по себе.

Логистическая регрессия, а не LDA, выбрана потому, что при 100 тысячах окон оценка ковариации уже не проблема, а LR с балансировкой классов проще калибровать. К силе регуляризации модель нечувствительна: $C = 0.01 / 0.1 / 1$ дают $0.5038 / 0.5039 / 0.5037$.

8.7 Смешивание сессионной и глобальной моделей

$$\log p_{\text{ЭЭГ}} = \log_{\text{softmax}} ((1 - w) \log p_s + w \log p_g), \quad w = \frac{k}{k + n}, \quad k = 1,$$

где n — число завершённых блоков. Во время блока b (после `fit_block(b-1)`) $n = b - 1$ и $w = 1/b$:

оцениваемый блок	2	3	4	5	6	7
вес глобальной модели w	0.50	0.33	0.25	0.20	0.17	0.14
вес сессионной модели $1 - w$	0.50	0.67	0.75	0.80	0.83	0.86

Такое расписание похоже на байесовский априор с «псевдосчётом»: глобальная модель весит столько же, сколько один блок данных сессии. Пока своих данных мало, решает в основном опыт других людей. Когда их много, решает индивидуальная модель. Параметр k подбирался по LOSO-баллу: $0.5 \rightarrow 0.5037$, $1 \rightarrow 0.5039$, $2 \rightarrow 0.5012$, $4 \rightarrow 0.4909$, $8 \rightarrow 0.4761$.

Если какую-то из моделей обучить нельзя, работает оставшаяся; если нельзя обе — равномерное распределение. Сессионную модель нельзя обучить, например, если в выборке меньше трёх классов.

Результат переноса — прежде всего в ранних блоках: min-F1 в блоке 2 у финала 0.371, у промежуточных вариантов (MVP, B1-fix, B3, B5 без нормировки логитов) — 0.21–0.26 (\$18.5).

9. NIRS-ветка

NIRS даёт два результата. Первый — отдельный ответ `y_nirs`, за который начисляется бонус до 20 баллов. Второй — вклад в гибридный ответ `y`. Код — `hbc/nirs.py` (NIRSEnd), обучение и применение — в `HybridDecoder.fit_block` и `predict`.

9.1 Входные сигналы

Каждая порция NIRS — это матрицы HbO и HbR размера $k \times 18$. Фронтенд собирает из них 38 сигналов:

$$x = [\text{HbO}_{1..18}, \text{HbR}_{1..18}, \overline{\text{HbO}}, \overline{\text{HbR}}],$$

где два последних — средние по всем каналам («глобальный сигнал»). Они нужны только для опции регрессии глобального сигнала, которая в финале выключена.

9.2 Фильтрация

НЧ-фильтр Баттерворта 2-го порядка с частотой среза **0.4 Гц**, SOS с сохранённым состоянием. Частота дискретизации берётся из `meta["fs_nirs"]`, поэтому фильтр одинаково корректен при 12.5 и 3.9 Гц. Фильтр убирает кардиальную пульсацию (~1 Гц) и высокочастотный шум и оставляет медленную гемодинамику. Его групповая задержка на частотах 0.05–0.2 Гц — около 0.6 с.

ВЧ-фильтр 0.01 Гц реализован, но выключен. С ним min-F1 NIRS 0.396, без него 0.399 (`E09_nirs`, `E09b`). Цикл «покой + воображение» длится ~21 с (≈ 0.05 Гц), и ВЧ-фильтр 2-го порядка с медленным переходным процессом искажает фазу именно этих компонент. Смещение и линейный дрейф и

так не влияют на признаки-наклоны (см. ниже), так что ВЧ-фильтр избыточен.

9.3 Синхронизация без зависимости от нарезки на порции

Это место, где исходный MVP протекал (§4.4). NIRS приходит пачками, и у отсчётов нет собственных меток времени — есть только `Frame`, который виден каркасу, но не классификатору. MVP назначал отсчётам время от конца порции `push`, поэтому при другой нарезке те же отсчёты получали другое время.

В финальном решении NIRS индексируется **номером отсчёта**. Каркас вместе с ЭЭГ-порцией $[t_0, t)$ отдаёт все отсчёты NIRS с `Frame` ≤ t . Значит, число доставленных к моменту t отсчётов $N(t)$ — свойство данных, а не нарезки. Признаки считаются по «последним L отсчётам до номера n »:

- в `predict` $n = N(t)$. Каждый вызов запоминает пару $(t, N(t))$;
- для **обучающего окна** с концом e в `fit_block` используется запомненное $N(e)$: для всех окон блоков ≥ 2 `predict` в момент e вызывался. Для окон блока 1 `predict` не вызывался, и $N(e)$ оценивается назад от ближайшего запомненного момента $T \geq e$ (момента `fit_block`) с номинальным шагом $\Delta = f_{\text{ЭЭГ}}/f_{\text{NIRS}}$:

$$n(e) = N(T) - \text{round}((T - e)/\Delta), \quad \Delta = 250/12.5 = 20 \text{ отсчётов ЭЭГ}.$$

Используются только уже доставленные отсчёты, так что это причинно. Тест инвариантности подтверждает: при нарезке порциями по 62 и по 1 отсчёту `y_nirs` совпадает побитово на всех 56 сессиях (§16).

9.4 Признаки: наклоны гемодинамики с лагами




Рис. 11. Как строятся NIRS-признаки. Для каждого из 38 сигналов берутся четыре 4-секундных окна, сдвинутых в прошлое на 0, 2, 4 и 6 с. В каждом окне считается наклон прямой, подогнанной методом наименьших квадратов. Признак описывает, как быстро и в какую сторону менялась гемодинамика 0–10 с назад. Для одного канала HbO это 4 числа, всего $38 \times 4 = 152$ признака.

Для сигнала x и лага $\ell \in \{0, 2, 4, 6\}$ с берётся окно из $L = 4 \cdot f_{\text{NIRS}}$ отсчётов (50 при 12.5 Гц, 16 при 3.9 Гц), заканчивающееся на отсчёте $m = n - \text{round}(\ell f_{\text{NIRS}})$. По нему считается МНК-наклон:

$$\beta = f_{\text{NIRS}} \cdot \frac{L \sum_i i x_i - \sum_i i \sum_i x_i}{L \sum_i i^2 - (\sum_i i)^2} \quad [\text{ед.}/\text{с}], \quad i \in [m - L, m).$$

Вычисляется за O(1). Фронтенд хранит накопленные суммы $\sum x$ и $\sum i x$ по всем отсчётам. Суммы по любому отрезку — разность двух элементов, а $\sum i$ и $\sum i^2$ считаются по формулам. Поэтому признаки для тысячи обучающих окон считаются векторно и мгновенно.

Линейная комбинация сигналов. Наклон линейен по сигналу, поэтому признаки сначала считаются для 38 исходных сигналов, а затем умножаются на матрицу W (38×38). Её строки:

- 18 каналов HbO и 18 каналов HbR как есть;
- **межполушарный контраст** HbO: среднее по 8 левым каналам (колонки 8–15) минус среднее по 8 правым (0–7);
- такой же контраст для HbR.

Итого **38 сигналов $\times$ 4 лага = 152 признака**. Окна с лагом 6 с захватывают последние 10 с NIRS.

ПОЧЕМУ НАКЛОНЫ, ЛАГИ И КОНТРАСТЫ

- **Наклон, а не уровень.** Уровень относительно базлайна зависит от выбора базлайна, а при строгом чередовании базлайн — это всегда «хвост» предыдущего класса. Наклон (производная) описывает, *начался ли* гемодинамический ответ, и не зависит от смещения и медленного дрейфа. Сравнение (E09_nirs, min-F1 NIRS): только наклон — 0.390, только уровень — 0.343, оба — 0.358.
- **Лаги = выученная форма гемодинамического ответа.** Ответ запаздывает на 1–2 с и достигает пика через 5–7 с. Линейный классификатор на наклонах с лагами 0...6 с — это FIR-фильтр по производной сигнала: веса разных лагов задают форму и задержку ответа, и модель учит её сама по данным. Лаги 0–6 с лучше, чем 0–4 с (0.396 против 0.388).
- **Межполушарные контрасты** — явный признак стороны. Это единственная возможность NIRS отличить левую руку от правой по корковой латерализации. Она слабая: AUC «левая/правая» по NIRS 0.578, но ненулевая.
- **Знак не защит.** Инверсию HbO/HbR (§4.3) классификатор выучивает сам.

Проверенные и отвергнутые варианты (сессионная оценка, E09_nirs ; min-F1 NIRS):

вариант	min-F1 NIRS	вывод
уровень + наклон, лаги 0–6, контрасты (исходный hemo)	0.358	уровень мешает
только уровень	0.343	хуже
только наклон	0.390	лучше
только наклон, без ВЧ-фильтра (финал)	0.399	лучший
CBSI $x = \frac{1}{2}(\text{HbO} - \alpha \text{HbR})$, α по прошлому	0.327	хуже: предполагает идеальную антикорреляцию
регрессия глобального сигнала (β по прошлому)	0.355	не помогает
средние по областям вместо каналов	0.315	теряется пространственная информация
каскад «покой/воображение $\rightarrow$ левая/правая» (как у авторов)	0.352	хуже одного трёхклассового LDA
логистическая регрессия вместо sLDA	0.361	хуже
сглаживание ответов NIRS, $\tau = 0 / 2 / 4$ с	0.363 / 0.325 / 0.274	сглаживание вредно

Строки получены в двух подсетках эксперимента с разными настройками сглаживания и ЭЭГ-ветки, поэтому корректно сравнивать соседние варианты, а не абсолютные значения между подсетками. Вывод устойчив: наклоны лучше уровней, а CBSI, GSR, области и каскад не помогают.

9.5 Классификатор NIRS и ответ `y_nirs`

В каждом `fit_block` NIRS-признаки считаются для всех обучающих окон прошедших блоков. Затем обучается та же схема, что для ЭЭГ: стандартизация, shrinkage-LDA с априорными $1/3$ и нормировка логитов ($T = 1$). Временного сглаживания нет: признаки и так медленные, а сглаживание только ухудшает качество.

$$y_{\text{nirs}} = \arg \max_k (\log p_{\text{NIRS}}(k) + b_k^{\text{NIRS}}),$$

где b^{NIRS} — смещения, откалиброванные отдельно под min-F1 NIRS (§11). В сессиях без NIRS ветка не создаётся, `y_nirs` не выдаётся, и решение работает на ЭЭГ.

9.6 Что NIRS реально различает

метрика (финал, LOSO, 54 сессии с NIRS)	значение
min-F1 NIRS	0.403 → бонус $5 + 15 \cdot 0.403 = 11.05$ балла
F1 покой / левая / правая	0.72 / 0.43 / 0.43
AUC «покой vs воображение»	0.81
AUC «левая vs правая»	0.578

NIRS силён в различении «покой/воображение» и слаб в различении рук. Это согласуется с EDA и объясняет его роль в гибриде. NIRS не решает, какая рука, но добавляет независимое свидетельство того, что человек вообще что-то представляет.

10. Слияние ЭЭГ и NIRS

10.1 Формула

$$\log p_{\text{H}}(k) = \log_{\text{softmax}_k} (0.8 \log p_{\text{ЭЭГ}}(k) + 0.2 \log p_{\text{NIRS}}(k)), \quad \text{т.е.} \quad p_{\text{H}} \propto p_{\text{ЭЭГ}}^{0.8} p_{\text{NIRS}}^{0.2}.$$

Это взвешенное геометрическое среднее, или «произведение экспертов». Если бы ЭЭГ и NIRS были условно независимы при известном классе, по формуле Байеса нужно было бы просто сложить их лог-вероятности. Веса меньше единицы ослабляют каждую модель с учётом того, что модальности частично зависимы и откалиброваны неидеально. Вес 0.8 у ЭЭГ отражает её большую надёжность.

Почему лог-линейное слияние, а не среднее вероятностей, как в исходном исследовании:

- Среднее вероятностей почти не даёт модальности «наложить вето». Уверенная модель доминирует независимо от второй.
- При лог-линейном слиянии NIRS может сдвинуть решение на границе «покой/воображение», где ЭЭГ сомневается. Там NIRS наиболее информативен.
- Слияние работает на **нормированных** логитах обеих моделей (§8.3), поэтому вес 0.8 означает именно относительное доверие, а не случайное соотношение масштабов.

10.2 Что ещё пробовали

вариант слияния (LOSO, E10_fusion)	F_{global}	P_{global}	F^{NIRS}
лог-линейное, фиксированный вес 0.8, без смещений	0.5039	0.6414	0.3986
лог-линейное, вес подобран по LOSO (0.7–0.8)	0.4988	0.6366	0.3986
стекинг: логистическая регрессия на 6 лог-вероятностях, C по LOSO	0.4979	0.6373	0.4009

вариант слияния (LOSO, E10_fusion)	F_{global}	P_{global}	F^{NIRS}
лог-линейное 0.8 + сессионные смещения (финал)	0.5067	0.6400	0.4032

Обученные веса и стекинг не лучше фиксированного 0.8 после нормировки логитов. Поэтому в финал взят вариант с наименьшим числом степеней свободы: меньше параметров, подобранных на тех же данных, — меньше риск переобучения под train. Параметр хранится в `artifacts/fusion.json`.

10.3 Без NIRS

Если NIRS нет (2 сессии train) или NIRS-модель ещё не обучена, гибридный ответ совпадает с ЭЭГ-ответом, и применяются смещения ЭЭГ-ветки. `y_nirs` в таких сессиях не выдаётся. Тест `test_edge_sessions.py` проверяет обе такие сессии и обе сессии с частотой NIRS 3.9 Гц.

11. Калибровка смещений под min-F1

11.1 Зачем

Argmax по откалиброванным вероятностям минимизирует долю ошибок, но не максимизирует **худшую** F1. У людей разная степень ERD, и модель может систематически «недодавать» одной из рук. Тогда эта рука становится худшим классом и определяет min-F1 сессии. Проще всего исправить это сдвигом решающих границ: к логитам прибавляется вектор $b = (0, b_2, b_3)$, и берётся $\arg \max_k (\log p(k) + b_k)$. Первая координата фиксирована нулём, потому что общий сдвиг всех логитов ничего не меняет.

11.2 Как подбираются смещения: leave-one-block-out

fit_block после блока n = 4: leave-one-block-out по прошедшим блокам




Рис. 12. Калибровка смещений в `fit_block`, начиная с 3-го блока. Для каждого прошедшего блока сессионные модели переобучаются без него и предсказывают его окна. Получаются честные вне-выборочные лог-вероятности для всех окон сессии. По ним координатным спуском подбирается сдвиг, максимизирующий min-F1. Результат усаживается к нулю.

Алгоритм (`HybridDecoder._calibrate_session`, `fusion.calibrate_bias`) запускается в `fit_block`, если завершено не менее трёх блоков.

- Для каждого прошедшего блока k сессионные LDA и MDM переобучаются на окнах **остальных** блоков и предсказывают окна блока k . Признаки, центр сессии и маска каналов меток не используют и не меняются.
- Вне-выборочная сессионная оценка смешивается с глобальной моделью. Глобальная модель от меток сессии не зависит, а вес берётся для $n - 1$ блоков, как было бы онлайн.

3. Так же переобучается без блока k NIRS-модель, и получаются вне-выборочные NIRS-оценки.
4. Строятся три набора вне-выборочных лог-вероятностей: ЭЭГ, NIRS и их слияние (§10).
5. Для каждого набора координатным спуском подбирается b . Для b_2 , затем b_3 перебираются 31 значение сетки $[-1.5, 1.5]$ с шагом 0.1, при остальных фиксированных; всего два прохода. Для всех кандидатов матрицы ошибок и min-F1 считаются векторно одним `bincount`. При равенстве выбирается значение, ближайшее к нулю.
6. Если годных окон меньше 30, калибровка пропускается.

Усадка. Оценка по 3–6 блокам шумная, поэтому итоговое смещение усаживается к глобальному. Глобальное смещение в `fusion.json` равно нулю: по LOSO оно получилось ≈ 0 после нормировки логитов.

$$b = \lambda b_{\text{сессия}} + (1 - \lambda) b_{\text{глоб}}, \quad \lambda = \frac{n}{n + 3} \quad (0.50 \text{ после блока } 3, 0.67 \text{ после блока } 6).$$

Пример (сессия 2025.12.04_N01, применённые смещения (b_1, b_2, b_3)):

после блока	гибрид	ЭЭГ	NIRS
3	(0, -0.10, 0)	(0, 0.05, 0.10)	(0, 0.30, 0.05)
4	(0, 0, 0.06)	(0, 0.06, 0.17)	(0, -0.06, 0.06)
6	(0, -0.07, 0.07)	(0, -0.13, 0)	(0, -0.07, 0)

Сдвиги небольшие, порядка 0.1–0.3 логита, и меняются от блока к блоку. Калибровка подправляет границы, а не переделывает модель.

ПОЧЕМУ ИМЕННО ТАК

- **Вне-выборочные, а не обучающие предсказания.** На своих обучающих окнах модель уверена и почти не ошибается, и подобранные по ним смещения были бы бессмысленны. LOBO даёт честную оценку того, как модель ошибается на новом блоке.
- **Отдельно для каждого ответа.** У гибрида, ЭЭГ и NIRS разные ошибки, поэтому смещения у каждого свои. NIRS-смещение напрямую влияет на бонус за `y_nirs`.
- **Эффект (LOSO):** min-F1 гибрида $0.5039 \rightarrow 0.5067$, NIRS $0.3986 \rightarrow 0.4032$. Прирост небольшой, но стабильный.
- **Цена — время `fit_block`.** Каждая калибровка — это n дополнительных переобучений сессионных моделей. Поэтому время `fit_block` растёт с номером блока. На машине разработчика оно ≈ 0.6 с после блока 7 при бюджете 1.5 с. На медленном процессоре запас может исчезнуть — см. §21.

12. Временная интеграция: почему в финале нет сглаживания

12.1 ЕМА по числу вызовов


В решении есть экспоненциальное сглаживание ответов по **числу вызовов** `predict`, а не по реальному времени (`hbci/smoothing.py`):

$$s_i = a s_{i-1} + (1 - a) \log p_i, \quad a = \exp\left(-\frac{1}{4\tau}\right),$$

где 4 — номинальное число вызовов в секунду. Сглаживание идёт в лог-пространстве с последующей нормировкой. Коэффициент не зависит от пауз, поэтому утечки через тайминг, как в MVP, здесь нет. В финале $\tau = 0$, то есть сглаживание выключено.

12.2 Почему оно вредно в этом протоколе

а) EMA по числу вызовов ($\tau > 0$): состояние переносится через паузу без затухания



б) усреднение ковариаций по 5 окнам сетки (финал): ≈ 2 с данных, только внутри подготовки и сегмента




Рис. 13. Две формы временной интеграции у границы сегментов. (а) EMA по числу вызовов: во время подготовки `predict` не вызывается, поэтому последнее состояние предыдущего сегмента (другого класса) без затухания попадает в первые ответы нового. (б) Усреднение ковариаций по 5 окнам сетки опирается на время отсчётов, а не на вызовы. В начале сегмента оно захватывает не больше 1 с подготовки и никогда не доходит до предыдущего сегмента.

Классы строго чередуются. Во время 1.5-секундной подготовки вызовов нет, так что EMA по вызовам переносит последнее состояние предыдущего сегмента прямо в начало следующего. А предыдущий сегмент всегда другого класса: после воображения идёт покой и наоборот. Чем длиннее τ , тем дольше ответы нового сегмента «тянут» в сторону старого класса. Это видно по AUC в первом временном бине сегмента (конец окна 1.0–2.5 с), сессионная оценка `E06_smoothing`:

τ , с	0	0.5	1	2	3	4
min-F1	0.452	0.458	0.451	0.413	0.363	0.318
AUC «покой/воображение» в 1.0–2.5 с	0.804	0.733	0.599	0.393	0.307	0.278

При $\tau \geq 2$ с AUC в начале сегмента падает **ниже 0.5**: модель там систематически отвечает классом предыдущего сегмента. В сессионном варианте небольшое сглаживание ($\tau = 0.5$ с) ещё давало +0.006. В финальном конвейере, с нормированными логитами и глобальной моделью, оно уже вредит: 0.4996 против 0.5039 при $\tau = 0$ (`E10_fusion/G_tau0.5`). Поэтому сглаживание выключено.

12.3 Чем оно заменено

Временную интеграцию взяло на себя усреднение ковариаций по 5 окнам сетки (§6.7). Оно даёт ≈ 2 с данных для оценки ковариации и привязано к времени *отсчётов*, а не вызовов. Поэтому оно не переносит состояние через паузу: в начале сегмента усреднение захватывает не больше 1 с подготовки (рис. 13, б).

13. Что происходит в `fit_block`: дообучение по блокам

`fit_block(b, labels)` вызывается каркасом после каждого блока, включая 1-й и 7-й. Все обучаемые части **переобучаются с нуля** на всех прошедших блоках. Инкрементальных обновлений моделей нет, поэтому поведение воспроизводимо и не зависит от истории вызовов. Единственный кэш — сумма $\log C$ для центра сессии, и он математически эквивалентен пересчёту.

1 Отметка NIRS. Запоминается число доставленных отсчётов NIRS $N(t)$ на текущий момент (`ne.mark`). По нему потом оцениваются $N(e)$ для окон блока 1 (§9.3).

- 2 Метки → окна.** Метки завершённого блока разбиваются на однородные сегменты. Для каждого сегмента с меткой 1/2/3 в список обучающих окон добавляются все точки сетки, чьё окно целиком лежит внутри сегмента (`_add_labels`). Счётчик завершённых блоков n увеличивается.
- 3 Ковариации обучающих окон.** Из хранилища берутся усреднённые по 5 окнам ковариации $\bar{S}$ для всех обучающих окон (`_S`). Сигнал заново не фильтруется.
- 4 Маска плохих каналов и матрица M .** Детектор (§6.6) смотрит на все прошлые данные, затем строится M : CAR по чистым каналам плюс выбор 11 каналов без плохих.
- 5 Центр сессии.** C_{ref} — лог-евклидово среднее всех прошлых окон сетки с инкрементальным кэшем (§7.3). Затем вычисляется $C_{\text{ref}}^{-1/2}$.
- 6 Признаки и сессионные модели.** Касательные векторы (396) всех обучающих окон → shrinkage-LDA с нормировкой логитов и TS-MDM (§8.2–8.4).
- 7 Глобальная модель.** В первом `fit_block` строится $M_{\text{глоб}}$ с интерполяцией плохих каналов. В каждом `fit_block` пересчитывается центр глобальной модели по всем прошлым окнам (§8.6).
- 8 NIRS-модель.** 152 признака всех обучающих окон → shrinkage-LDA с нормировкой логитов (§9.5).
- 9 Калибровка смещений** — если завершено ≥ 3 блоков: LOBO, подбор b под min-F1, усадка (§11).

Время. По отчёту разработчика `fit_block` занимает ≈ 0.09 с после блока 1 и растёт примерно до 0.6 с после блока 7 на незагруженной машине. Рост почти целиком даёт LOBO-калибровка: после блока n это n дополнительных переобучений. Тест `test_timing.py` на самой длинной сессии в один поток — 0.59–0.61 с. Максимум в официальном прогоне — 1.1–1.2 с, когда два прогона шли одновременно. Бюджет 1.5 с. Чтобы первый вызов не платил за ленивую инициализацию numpy и scikit-learn, в `load` выполняется «прогрев»: пробное обучение LDA/LR на случайных данных и пробный `logm`.

14. Что происходит в `predict`

`predict()` вызывается в конце каждого оцениваемого окна и ничего не обучает.

- 1. Ковариация текущего окна.** Момент вызова t совпадает с точкой сетки, поэтому $\bar{S}$ берётся из хранилища по индексу $k = (t - 250)/62$, усреднённая по 5 окнам. Если бы t не лежал на сетке, ковариация посчиталась бы из хвоста буфера; с каркасом `gun.py` такого не бывает.
- 2. Сессионная ЭЭГ-модель.** $M\bar{S}M^\top \rightarrow \text{OAS} \rightarrow C_{\text{ref}}^{-1/2}(\cdot)C_{\text{ref}}^{-1/2} \rightarrow \log \rightarrow$ вектор t (396) $\rightarrow \log p_{\text{LDA}}$ и $\log p_{\text{MDM}} \rightarrow$ среднее $\rightarrow \log p_s$.
- 3. Глобальная ЭЭГ-модель.** То же с $M_{\text{глоб}}$ и центром глобальной модели $\rightarrow$ логистическая регрессия $\rightarrow \log p_g$.
- 4. Смесь:** $\log p_{\text{ЭЭГ}}$ с весом $w = 1/(1 + n)$ (§8.7). Сглаживание при $\tau = 0$ — тождественное преобразование.
- 5. NIRS.** Запоминается $N(t)$, считаются 152 наклона по последним отсчётам (§9.4), затем LDA $\rightarrow \log p_{\text{NIRS}}$.
- 6. Слияние:** $\log p_{\text{H}} = \log_{\text{softmax}}(0.8 \log p_{\text{ЭЭГ}} + 0.2 \log p_{\text{NIRS}})$.

7. Ответы:

$$y = \arg \max(\log p_H + b^{\text{гиб}}), \quad y_{\text{eeg}} = \arg \max(\log p_{\text{ЭЭГ}} + b^{\text{ЭЭГ}}), \quad y_{\text{nirs}} = \arg \max(\log p_{\text{NIRS}} + b^{\text{NIRS}}).$$

Если NIRS нет, y берётся из ЭЭГ-ветки со смещением $b^{\text{ЭЭГ}}$.

8. Возврат: `{"y": y, "y_eeg": y_eeg, "y_nirs": y_nirs, "p": вероятности гибрида}`.

Время: в среднем 0.5–1 мс, максимум 14–30 мс при бюджете 200 мс. Самое дорогое — 12 собственных разложений матриц 11×11 (6 полос $\times$ 2 модели) и одно умножение 3×396 .

15. Одна сессия от начала до конца

Пример — сессия 2025.12.04.13.29.33_N01: 1549 оцениваемых окон, 7 блоков, NIRS 12.5 Гц.

момент	что происходит	обучающих окон	вес глобальной модели в predict	смещения в predict
блок 1 (≈ 88 с)	только push: фильтрация, 355 ковариаций на сетке; predict не вызывается	—	—	—
fit_block(1)	маска каналов, центр по 355 окнам, LDA + MDM, центр глобальной модели, NIRS-LDA	258	—	—
блок 2	259 вызовов predict	—	0.50	нет
fit_block(2)	всё заново на двух блоках	517	—	—
блок 3	predict	—	0.33	нет
fit_block(3)	+ первая LOBO-калибровка (3 переобучения)	773	—	—
блок 4	predict	—	0.25	да, $\lambda = 0.50$
fit_block(4)	LOBO: 4 переобучения	1031	—	—
блок 5	predict	—	0.20	да, $\lambda = 0.57$
fit_block(5)	LOBO: 5 переобучений	1289	—	—
блок 6	predict	—	0.17	да, $\lambda = 0.63$
fit_block(6)	LOBO: 6 переобучений	1548	—	—
блок 7	predict	—	0.14	да, $\lambda = 0.67$
fit_block(7)	вызывается каркасом после последнего блока; на ответы не влияет, но входит в тайминг	1807	—	—

Итог этой сессии в официальном прогоне results/metrics: min-F1 0.788, macro-recall 0.856, min-F1 NIRS 0.471. Это одна из хороших сессий: разброс по сессиям велик, см. §18.6.

ЧАСТЬ III

Честность, результаты и проверки

16. Защита от утечек

По ТЗ доказанная утечка из будущего или использование меток как признаков обнуляет результат. Поэтому защита от утечек здесь — часть архитектуры и отдельный набор автоматических тестов, а не формальность.

16.1 Откуда в этой задаче может «протечь» будущее

канал утечки	как мог бы возникнуть	как закрыт в решении
будущие отсчёты в обработке	двунаправленная фильтрация (<code>filtfilt</code>), нормировка по всей сессии	только IIR-фильтры с сохранённым состоянием; центры, маски и стандартизация — по прошлому, пересчёт только в <code>fit_block</code>
метки текущего или будущих блоков	обучение на ещё не завершённом блоке, метки как признаки	метки читаются только в <code>fit_block</code> и только для завершённых блоков; в признаках меток нет
тайминг вызовов	размер порций <code>push</code> , паузы между <code>predict</code> , число вызовов с начала сегмента выдают границы сегментов, а при чередовании — класс	признаки на фиксированной сетке отсчётов; NIRS по номеру отсчёта; сглаживание по вызовам выключено; побитовая инвариантность проверена тестом
глобальная модель видела тестового испытуемого	обучение междубъектной модели на всех испытуемых и оценка на них же	вся оценка — LOSO; тест проверяет, что LOSO-модель не содержит сессий оцениваемого испытуемого
внешний датасет	полный датасет исследования на NITRC, вероятно, содержит закрытый тест	не используется ни для обучения, ни для валидации
чтение файла сессии	<code>classifier.py</code> читает <code>.mat</code> напрямую	не читает; данные приходят только через <code>push</code>

16.2 Автоматические тесты

Все тесты запускаются одной командой `bash tests/run_all_tests.sh`. Общий симулятор `tests/sim.py` воспроизводит порядок событий `run.py` и позволяет менять нарезку порций `push`.

тест	что делает	результат финальной конфигурации
<code>test_causal.py</code>	Заменяет все данные после момента $T = 0.6$ длины сессии шумом: ЭЭГ и NIRS с <code>Frame > T</code> . Сравнивает ответы до T . Заодно проверяет, что после T ответы изменились, то есть тест чувствителен.	0 расхождений до T
<code>test_chunk_invariance.py</code>	Прогоняет сессию трижды: стандартными порциями каркаса, порциями ровно по 62 отсчёта и участком из 2000 отсчётов по одному отсчёту. Ответы <code>y</code> и <code>y_nirs</code> должны совпасть на 100 %.	56/56 сессий, 86 746 окон, 0 расхождений (<code>results/tests.json</code>). У исходного MVP — 10 расхождений <code>y</code> и 22 <code>y_nirs</code> на одной сессии
<code>test_label_isolation.py</code>	Случайно переставляет метки сегментов в блоках > 3 , сохраняя границы. Ответы в блоках ≤ 3 не должны измениться, в блоках > 3 — должны.	0 изменений на 515 окнах блоков ≤ 3 ; 344 изменения позже
<code>test_edge_sessions.py</code>	Прогоняет через <code>run.py</code> 2 сессии без NIRS (<code>y_nirs</code> должен отсутствовать) и 2 сессии с NIRS 3.9 Гц (<code>y_nirs</code> $\in \{1, 2, 3\}$)	OK

тест	что делает	результат финальной конфигурации
test_timing.py	Самая длинная сессия, один поток BLAS: <code>predict < 0.05 c</code> , <code>fit_block < 1.0 c</code>	0.0007 / 0.61 c (машина разработчика)
test_artifacts_loso.py	Для всех каталогов LOSO-моделей проверяет по метаданным, что модель испытуемого S не обучалась на его сессиях	13 наборов × 14 моделей — ОК

16.3 История утечки в MVP — почему это важно

Исходный MVP получал $F_{\text{global}} = 0.472$ и выглядел сильнее «честных» вариантов. Разложение (`E01_b1fix`) показало, откуда это:

вариант MVP	F_{global}	P_{global}	балл
исходный: EMA по реальному времени, масштаб NIRS по текущему окну	0.4718	0.6176	57.58
только EMA переведена на счёт вызовов	0.4191	0.5494	52.06
только исправлен масштаб NIRS	0.4740	0.6193	57.77
оба исправления (B1-fix)	0.4213	0.5506	52.20
B1-fix без сглаживания ($\tau = 0$)	0.4525	0.5860	55.58

Почти 5.5 балла MVP давала граница сегмента, «подсмотренная» через паузу между вызовами. Это не прямое чтение меток, но именно та зависимость от тайминга, которую ТЗ запрещает. В финальном решении такой зависимости нет, и это доказано побитовой инвариантностью. Поэтому его 60.65 — честная цифра, которую не нужно мысленно уменьшать.

17. Как оценивалось качество

17.1 Три режима оценки

режим	что обучено на чём	когда честен
сессионный	только онлайн-дообучение на прошедших блоках этой же сессии; глобальных компонентов нет	всегда честен, но не использует перенос
LOSO	глобальная модель для испытуемого S обучена на 13 других испытуемых	честная оценка для новых людей — главный режим
in-sample	глобальная модель обучена на всех 14, включая оцениваемого	завышен; так получены официальные <code>results/metrics</code> (ТЗ требует онлайн-прогон финальных артефактов на train)

Закрытый тест, скорее всего, состоит из новых испытуемых (§2.1), поэтому главная цифра решения — **LOSO**: $F_{\text{global}} = 0.507$, **балл 60.65**. Цифра 63.30 из `results/metrics` завышена: там глобальная модель уже видела этих людей.

17.2 Выбор финальной конфигурации без самообмана

- **Кандидаты.** 20 LOSO-конфигураций из `E10_fusion` (список — `tools/grids/nested_candidates.json`). Правило выбора — LOSO-балл $60F + 30P + 5 + 15F^{\text{NIRS}}$.
- **Вложенная проверка (nested).** 7 внешних фолдов по 2 испытуемых. В каждом фолде конфигурация выбирается по 12 остальным испытуемым и оценивается на двух отложенных. Во **всех 7** фолдах выбирается одна и та же конфигурация, поэтому nested-оценка совпадает с LOSO: 60.65.

- **Оговорка.** Часть решений принималась раньше, по сессионным прогонам на всех 56 сессиях: выбор NIRS-признаков, отказ от сглаживания, `cov_avg_n`. Nested-цикл это не учитывает. Это небольшой источник оптимизма, и он честно указан в отчёте.

17.3 Неопределённость

- **Бутстрап-ДИ** строится двухуровнево: сначала ресэмплируются испытуемые, потом их сессии, 2000 повторов. Так учитывается, что сессии одного человека похожи. 95 % ДИ балла финала — [54.4; 66.8]. Ширина определяется в основном различиями между людьми.
- **Сравнения** — парные по испытуемым (Wilcoxon): у всех вариантов одни и те же люди, поэтому межиндивидуальная изменчивость вычитается.

18. Результаты

Все числа ниже — онлайн-симуляция через замороженные `run.py` и `score.py` на 56 сессиях train. Итог — невзвешенное среднее по сессиям.

18.1 Главное

решение	F_{global}	P_{global}	$F_{\text{global}}^{\text{NIRS}}$	штраф	балл без жюри	оценка
MVP (исходный)	0.4718	0.6176	0.3828	0	57.58	содержит утечку тайминга
MVP без утечки (B1-fix)	0.4213	0.5506	0.3604	0	52.2	честно, сессионно
финал	0.5067	0.6400	0.4032	0	60.65	LOSO: новые испытуемые; nested = LOSO
финал, results/metrics	0.5391	0.6635	0.4032	0	63.30	in-sample для глобальной модели

Статистика сравнения (LOSO, парно по 14 испытуемым, `E12_final_loso/compare_mvp.json`):

- финал против исходного MVP: **+0.035 min-F1**, лучше у 11 из 14 испытуемых, Wilcoxon $p = 0.03$, 95 % бутстрап-ДИ разницы [0.001; 0.073]. MVP при этом пользуется утечкой;
- финал против честного MVP (B1-fix): **+0.085 min-F1** (12/14, $p = 0.0006$) и **+0.089 macro-recall** (14/14, $p = 0.0001$).

18.2 От MVP к финалу: вклад каждого шага




Рис. 14. Вклад шагов в F_{global} . Оранжевый — снижение, бирюзовый — рост. Первый шаг вниз — удаление утечки тайминга. Главные приросты дают межсубъектный перенос вместе с MDM и NIRS-наклонами (+0.024) и нормировка логитов (+0.023).

шаг	конфигурация	F	P	NIRS F	оценка
MVP	log-power 8–30 Гц, all17, sLDA, EMA по Δt	0.4718	0.6176	0.3828	утечка
B1-fix	MVP + EMA по вызовам + масштаб NIRS из fit	0.4213	0.5506	0.3604	сессия
B1-fix, τ = 0	без сглаживания	0.4528	0.5864	0.3919	сессия
B2	пайплайн авторов: FB-CSP + sLDA, NIRS-каскад, среднее вероятностей	0.4138	0.5561	0.3664	сессия
B3	касательное пространство + sLDA, sensorimotor11, cov_avg_n = 5	0.4525	0.5849	0.3630	сессия
B4	MDM (риманово расстояние)	0.3948	0.5460	0.3630	сессия
B5	B3 + глобальная модель	0.4534	0.5880	0.3582	LOSO
+	TS+MDM, NIRS-наклоны, перецентрирование	0.4810	0.6153	0.3986	LOSO
+	нормировка логитов, w = 1/(1+n)	0.5039	0.6414	0.3986	LOSO
финал	+ сессионные смещения (LOBO)	0.5067	0.6400	0.4032	LOSO

Полная таблица из 130 прогонов с доверительными интервалами — [results/summary.md](#), хронология решений — [research/WORKLOG.md](#).

18.3 Сравнение пайплайнов по сессиям





Рис. 15. min-F1 гибрида по сессиям (точки), средние и 95 % бутстрап-ДИ (ромбы) для основных пайплайнов. У финала выше и среднее, и нижняя часть распределения: плохих сессий меньше. Правый столбец — вариант с лобными и затылочными каналами (all17), о нём §19 и §21.

18.4 ЭЭГ, NIRS и гибрид при одинаковом порядке обучения

T3 рекомендует сравнить модальности на одних данных и при одинаковом порядке обучения. Финальный декодер выдаёт все три ответа одновременно: y_{eeg} , y_{nirs} и y . Поэтому сравнение идёт внутри одного прогона.

Модальности, одинаковый порядок обучения (54 сессии с NIRS)



F1 по классам




Рис. 16. Слева — min-F1 по сессиям для ЭЭГ, NIRS и гибрида (54 сессии с NIRS, LOSO). Справа — F1 по классам. Гибрид лучше ЭЭГ по всем трём классам.

модальность (финал, LOSO, 54 сессии)	min-F1	F1 покой / левая / правая
ЭЭГ (y_{eeg})	0.474	0.80 / 0.51 / 0.50
NIRS (y_{nirs})	0.403	0.72 / 0.43 / 0.43
гибрид (y)	0.509	0.84 / 0.54 / 0.53

Гибрид лучше ЭЭГ на **+0.035 min-F1**. NIRS помогает прежде всего различать покой и воображение (AUC 0.81). Это сдвигает решения и для рук, потому что меньше окон воображения теряется в «покое». В исходном онлайн-исследовании гибрид ЭЭГ-only не превзошёл. Здесь выигрыш есть, видимо, благодаря лог-линейному слиянию нормированных логитов вместо среднего вероятностей и более сильной ЭЭГ-ветке.

18.5 По блокам: как растёт качество с накоплением данных




Рис. 17. min-F1 гибрида по блокам: модель в блоке b обучена на блоках 1...b-1. Финал (розовая линия) заметно лучше в ранних блоках — это эффект межсубъектной модели — и выходит на плато к блокам 5–7.

блок	2	3	4	5	6	7
min-F1 гибрида (финал, LOSO)	0.371	0.408	0.439	0.499	0.513	0.515
macro-recall гибрида	0.565	0.602	0.628	0.683	0.679	0.684
min-F1 ЭЭГ	0.342	0.392	0.418	0.446	0.460	0.485

В блоке 2 у финала 0.371 против 0.21–0.26 у промежуточных вариантов. После блока 1 в сессии всего по 2 сегмента на руку, и здесь больше всего помогает опыт других людей.

18.6 По испытуемым и сессиям

Разброс между людьми огромный: min-F1 сессий от **0.25 до 0.87** (LOSO), медиана 0.47. Это ожидаемая «BCI-неэффективность»: часть людей не даёт устойчивого ERD, и это известная проблема ИМК на моторном воображении, не специфичная для решения.

Таблица. Средние по сессиям каждого испытуемого (финал, LOSO)

испытуемый	сессий	min-F1 гибрида	macro-recall	min-F1 ЭЭГ	min-F1 NIRS	AUC покой/вообр. (ЭЭГ)	AUC Л/П (ЭЭГ)
N13	4	0.782	0.839	0.711	0.554	0.947	0.887
N17	4	0.663	0.749	0.625	0.439	0.890	0.886
N01	3	0.651	0.729	0.627	0.434	0.864	0.853
N11	4	0.626	0.740	0.568	0.438	0.969	0.754

испытуемый	сессий	min-F1 гибрида	macro-recall	min-F1 ЭЭГ	min-F1 NIRS	AUC покой/вообр. (ЭЭГ)	AUC Л/П (ЭЭГ)
N18	4	0.600	0.735	0.576	0.458	0.988	0.700
N03	4	0.567	0.705	0.577	0.347	0.952	0.792
N06	4	0.475	0.624	0.425	0.406	0.889	0.590
N08	4	0.466	0.626	0.435	0.393	0.907	0.576
N02	4	0.434	0.578	0.375	0.425	0.879	0.568
N10	4	0.427	0.563	0.419	0.331	0.810	0.673
N09	4	0.421	0.590	0.447	0.319	0.960	0.568
N14	5	0.392	0.538	0.356	0.334	0.812	0.564
N15	4	0.354	0.515	0.282	0.419	0.705	0.564
N16	4	0.302	0.476	0.266	0.364	0.715	0.540

Посчитано по `results/experiments/E12_final_loso/final/per_session_extra.csv`. Для N02 и N03 в среднее NIRS не входит сессия без NIRS.

Из таблицы видно, где узкое место. **Покой от воображения отличается хорошо почти у всех:** AUC 0.8–0.99. **Левую руку от правой** хорошо различают только у половины испытуемых: AUC 0.75–0.89 у N13, N17, N01, N11, N03, N18. У остальных — 0.54–0.67. Поэтому худший класс сессии — всегда одна из рук: левая в 22 сессиях, правая в 34, покой ни разу.




Рис. 18. Матрицы ошибок гибрида: доля от истинного класса. Лучшая сессия (N13, min-F1 0.87) почти диагональна. Медианная (N03, 0.47): покой узнаётся хорошо (78 %), но 43 % окон правой руки уходят в «левую» — путаются руки. Худшая (N16, 0.25): половина окон воображения классифицируется как покой — ERD почти не виден. Сессия без NIRS (N02, 0.33): руки путаются и между собой, и с покоем.

Матрицы ошибок и метрики каждой сессии лежат в `results/metrics/per_session/*.json` (in-sample) и `results/experiments/E12_final_loso/final/per_session/*.json` (LOSO).

18.7 Время

величина	значение	бюджет
predict, среднее	≈ 0.5–1 мс	200 мс
predict, максимум	14–30 мс	200 мс
fit_block после блока 1	≈ 0.09 с	1.5 с
fit_block после блока 7, незагруженная машина	≈ 0.6 с	1.5 с
fit_block, максимум в официальном прогоне (два прогона параллельно)	1.1–1.2 с	1.5 с

величина	значение	бюджет
штрафы	0	—

Цифры — с машины разработчика. О зависимости от скорости процессора — §21.

19. Контроли: модель декодирует моторное представление, а не артефакты

Высокое качество само по себе не доказывает, что модель «читает» моторную кору. В этих данных есть три сильных источника информации, не связанных с КМП: стимулятор, взгляд и тайминг протокола. Ниже — эксперименты, каждый из которых проверяет одну альтернативную гипотезу. Код — `tools/controls.py`, `tools/haufe.py`, результаты — `results/experiments/E11_controls/`.

19.1 Сводка

контроль	результат	вывод
Спектр: полосы до 30 / 40 / 100 Гц	min-F1 0.507 / 0.500 / 0.492; AUC «покой/воображение» 0.877 / 0.876 / 0.887	Утечка ФЭС реальна: AUC растёт, когда модель видит 83 Гц. Но финал с полосами ≤ 30 Гц её не видит, а доступ к ней не повышает итоговое качество
Каналы: sensorimotor9 / sensorimotor11 / all17	min-F1 0.500 / 0.507 / 0.533 ; AUC Л/П 0.667 / 0.674 / 0.698	Лобно-затылочные каналы (взгляд, затылочная α) добавили бы $\approx +0.026$; в финал не взяты (§21)
Артефактные декодеры — тот же онлайн-протокол, только артефактные признаки	ГЭОГ: min-F1 0.30 (AUC Л/П 0.64); ФЭС 80–86 Гц: 0.32 (AUC п/в 0.70); лобно-затылочные каналы: 0.35	Артефакты информативны, но как декодеры намного слабее финала (0.507)
Связь с ГЭОГ-декодером по сессиям	min-F1: $\rho = 0.17$ ($\rho = 0.21$), $R^2 = 0.02$; AUC Л/П: $\rho = 0.31$ ($\rho = 0.02$)	Качество финала почти не объясняется «силой взгляда» в сессии
Паттерны Хауфе (log-power + sLDA на тех же каналах и полосах)	μ , контраст «левая – правая»: $C4 = -0.37$, $C3 = +0.16$; CSP-фильтры ERD пайплайна авторов: левая $\rightarrow C4$, правая $\rightarrow C3$	Модель смотрит туда, куда должна: контралатеральная μ -десинхронизация
Время внутри сегмента — конец окна 1.0–2.5 с, до нарастания ФЭС	min-F1 0.490 (поздние бины 0.49–0.51); AUC п/в 0.894, Л/П 0.689; эмпирический шанс 0.24	Качество есть ещё до включения стимулятора
Стратификация проб по силе ФЭС	recall воображения 0.58 (артефакт > 6 дБ) против 0.47 (< 2 дБ), $\rho = 10^{-4}$, но та же разница уже в первые 2.5 с (0.61 против 0.45)	Это эффект отбора (ФЭС включалась там, где ERD и так был заметен), а не использование артефакта
Пермутационный нуль (14 сессий, по 50 перестановок)	Л $\leftrightarrow$ П внутри блоков: 0.487 против нуля 0.374 (максимум 0.406); фаза покой/воображение: 0.487 против 0.236 (максимум 0.397); $\rho = 0.02$ в обоих случаях	Качество значимо выше случайного даже при сохранённой структуре протокола
Инвариантность к таймингу	56/56 сессий, 0 расхождений	Ответы не зависят от порций и пауз
Нейрофизиологическая согласованность по сессиям	min-F1 ~ сила μ -латерализации: $\rho = 0.66$ ($\rho = 4 \cdot 10^{-8}$); AUC п/в ~ глубина раннего ERD: $\rho = -0.72$ ($\rho = 4 \cdot 10^{-10}$)	Модель работает лучше там, где сильнее ERD и его латерализация

19.2 Модель работает до включения стимулятора




Рис. 19. Качество в зависимости от положения окна внутри сегмента. Ранний бин (конец окна 1.0–2.5 с от начала) лежит до нарастания тока ФЭС. У финала (жёлтые столбцы) качество в раннем бине почти такое же, как в поздних: min-F1 0.49, AUC «покой/воображение» 0.89, AUC «левая/правая» 0.69. У MVP с утечкой, наоборот, ранний бин заметно хуже поздних.

Если бы модель опиралась на стимулятор, в первые секунды сегмента, пока ток ещё не вырос, её качество было бы близко к случайному. Оно почти такое же, как в конце сегмента. Значит, модель видит нейрофизиологический сигнал, который появляется сразу, — ранний ERD.

19.3 Взгляд и стимулятор не объясняют качество




Рис. 20. Слева — AUC «левая/правая» финала против AUC «левая/правая» контрольного ГЭОГ-декодера по сессиям: связь слабая ($\rho = 0.31$). Справа — AUC «покой/воображение» финала против силы ФЭС-артефакта в сессии: $\rho = 0.29$. Слабая положительная связь ожидаема из-за эффекта отбора: стимуляция включалась у тех, у кого исходный декодер хорошо работал.

19.4 Куда «смотрит» модель: паттерны Haufe

Веса линейного классификатора — это фильтр, а не топография источника. Большой вес может означать и сигнал, и подавление шума. Чтобы увидеть, какие области несут различия классов, строятся **паттерны** $A = \Sigma_X w / \text{var}(\hat{s})$ (Haufe et al., 2014). Для модели в касательном пространстве паттерны не интерпретируются напрямую в терминах электродов. Поэтому они посчитаны для log-power + sLDA на тех же 11 каналах и полосах и для CSP-фильтров пайплайна авторов.

Паттерны Haufe: где модель «видит» различия классов (среднее по 56 сессиям)




Рис. 21. Паттерны Haufe, среднее по 56 сессиям. Верхний ряд — μ 8–12 Гц: «левая – покой» и «правая – покой» — это ERD над обоими полушариями с максимумом над C3/C4. «Левая – правая» даёт отрицательный паттерн над C4 и положительный над C3, то есть контралатеральную десинхронизацию. Средний ряд — β , та же картина слабее. Нижний ряд — CSP-фильтры ERD пайплайна авторов: для левой руки максимум над C4, для правой — над C3.

19.5 Пермутационный нуль: как его строили

Обычная перестановка меток окон здесь даёт слишком оптимистичный нуль: она разрушает и сигнал, и структуру протокола. Поэтому строились два нуля, сохраняющих чередование.

- **Л⇌П внутри блоков.** В каждом блоке метки сегментов воображения случайно переставляются между собой. Метки покоя остаются на месте. Проверяется, что модель различает руки, а не только фазу цикла.
- **Фаза покой/воображение.** В ТЗ предложен «циклический сдвиг меток сегментов на 2 позиции». При строгом чередовании такой сдвиг оставляет все метки покоя на сегментах покоя

и нуля не даёт. Поэтому в каждом блоке с вероятностью $\frac{1}{2}$ метки сдвигаются на **один** сегмент. Чередование сохраняется, но связь «сигнал $\leftrightarrow$ класс» между блоками рвётся.

На 14 сессиях (по одной на испытуемого) с 50 перестановками каждого типа реальное качество (0.487) выше **всех** перестановок в обоих случаях. $p = 1/51 \approx 0.02$ — минимально возможное значение при 50 перестановках. ЭЭГ-only: 0.459 против нулей 0.351 и 0.237.

20. Что пробовали и почему отказались

Финальная конфигурация — результат примерно 130 онлайн-прогонов на всех 56 сессиях. Ниже — отвергнутые варианты с числами. «Сессия» — сессионная оценка, «LOSO» — оценка на новых испытуемых. Числа внутри одной группы сравнимы между собой.

что пробовали	результат	почему не взяли
признаки log-power по каналам (как в MVP), без сглаживания	0.453 (сессия) против 0.452 у касательного пространства	В сессионном режиме равны. Касательное пространство выбрано, потому что оно совместимо с перецентрированием и межсубъектным переносом — они и дали основной прирост
пайплайн авторов: FB-CSP (4–7/7–13/13–30 Гц, 2 фильтра на класс) + sLDA, NIRS-каскад, среднее вероятностей	0.414 / 0.408 (сессия; all17 / sm11)	хуже TS + sLDA (0.452); CSP неустойчив при двух сегментах на класс
MDM с римановым расстоянием как единственный классификатор	0.395 (сессия)	лучше всех ранжирует, но плохо откалиброван; полезен только в ансамбле
MDM с римановым расстоянием в ансамбле	fit_block до 2.47 с	превышение бюджета; лог-евклидова версия быстрее при том же качестве
логистическая регрессия вместо sLDA в сессии (C = 0.01 / 0.1 / 1)	0.420 / 0.428 / 0.428 (сессия)	хуже sLDA (0.452) по argmax
референс: без / малый лапласиан	0.449 / 0.451 против 0.452 у CAR	разница в пределах шума
среднее Карчера вместо лог-евклидова; Ledoit-Wolf вместо OAS	0.4517; 0.4523 против 0.4521	равны; лог-евклидово быстрее и инкрементально
пропуск начала сегмента при обучении, 0.5 / 1 с	0.449 / 0.446 против 0.452	ранние окна содержат полезный ERD
cov_avg_n = 3 / 8	0.4505 / 0.4476 против 0.4525 при n = 5	при n = 8 усреднение захватывает предыдущий сегмент (§6.7)
полосы до 40 / 100 Гц	финал: 0.500 / 0.492 против 0.507	хуже и открывает дорогу артефакту ФЭС
sensorimotor9 (без T7/T8)	финал: 0.500	хуже
all17 (+ fp1/fp2/f7/f8/o1/o2)	финал: 0.533 (+0.026)	лучше, но прирост частично за счёт взгляда и зрительной α ; решение команды — не брать (§21)
сглаживание EMA по вызовам, $\tau = 0.5$ с	финал: 0.4996 против 0.5039	переносит класс предыдущего сегмента (§12)
только глобальная модель ($k = \infty$)	0.389 (LOSO)	хорошо ранжирует, но порог у нового человека смещён
центр глобальной модели только по блоку 1	0.4772 против 0.4810	адаптивное перецентрирование лучше
вес глобальной модели $k = 2 / 4 / 8$	0.501 / 0.491 / 0.476 против 0.504	после нормировки логитов лучше $k = 1$

что пробовали	результат	почему не взяли
обученные веса слияния, стекинг, глобальные смещения	0.4988 / 0.4979 / 0.4988 против 0.5039	не лучше фиксированного 0.8; больше степеней свободы
NIRS: уровни, CBSI, GSR, области, каскад, LR, ВЧ-фильтр, сглаживание	см. §9.4	все хуже наклонов без ВЧ
компактная CNN (EEGNet / ShallowConvNet, фаза 7 плана)	не делалась	римановы методы с переносом закрыли главную проблему ранних блоков. При 2 сегментах на класс внутри сессии CNN почти наверняка переобучилась бы. По плану CNN оправдана только при выигрыше ≥ 0.02 с пройденными контролями

21. Ограничения, риски и что можно улучшить

21.1 Открытые научные вопросы

- Лобные и затылочные каналы — решение команды.** Вариант all17 даёт +0.026 min-F1 (LOSO-балл 62.8 против 60.65) и лучше различает руки (AUC 0.698 против 0.674). Но на этих каналах сильнее всего проявляется взгляд на стрелку (§4.2) и зрительная α -активность. Часть прироста, скорее всего, — не моторное представление. По умолчанию выбран консервативный `sensorimotor11`. Переключение — `eeg.channels = "all17"` в `artifacts/config.json` с переобучением `global_eeg.joblib`.
- Что именно видит NIRS.** Различение «покой/воображение» по NIRS может в значительной мере опираться на фазу 21-секундного цикла чередования и системные ответы на ФЭС, а не на корковую активацию. Левую и правую руку NIRS различает слабо (AUC 0.578).
- ФЭС и ERD полностью не разделить.** Стимуляция сама вызывает соматосенсорный ERD и включалась по решению исходного декодера. Контроли показывают, что модель работает и до включения ФЭС (§19.2). Однако часть позднего «воображения» может быть ответом на стимуляцию: в полосе ≤ 30 Гц он спектрально неотличим от КМП.
- Небольшой неучтённый оптимизм.** Часть решений (NIRS-признаки, отказ от сглаживания, `cov_avg_n`) принималась по прогонам на всех 56 сессиях до формирования списка кандидатов для nested-проверки.

21.2 Практический риск: время `fit_block` на медленном процессоре

ПРОВЕРКА ПРИ ПОДГОТОВКЕ ЭТОГО ДОКУМЕНТА

Отчёт разработчика даёт `fit_block` ≈ 0.6 с после блока 7 на незагруженной машине разработчика. При подготовке документа финальное решение прогнали на одной сессии (2025.12.04_N01) в облачном контейнере: 2 vCPU Intel Xeon 2.1 ГГц, закреплённые версии numru 2.2.6, scipy 1.15.3, scikit-learn 1.7.2. Время `fit_block`, с:

конфигурация	блок 3	блок 4	блок 5	блок 6	блок 7
финал, потоки BLAS по умолчанию	1.0	1.1	1.5	1.7–2.4	2.2–2.4
финал, <code>OMP_NUM_THREADS=1</code> <code>OPENBLAS_NUM_THREADS=1</code>	0.42	0.60	0.90	1.0	1.3–1.4
без калибровки смещений (<code>bias.mode = "none"</code>), 1 поток	0.19	0.28	0.40	0.43	0.63

На такой машине с настройками по умолчанию `fit_block` после блоков 6–7 выходит за бюджет 1.5 с. Штраф считается как сумма превышений по сессиям с потолком –10. Даже 1–2 балла на сессию быстро дают **максимальный штраф –10**, а это намного больше выигрыша от калибровки смещений ($\approx +0.2$ балла: 60.45 $\rightarrow$ 60.65). Время `predict` (≤ 10 мс) в любом случае далеко от бюджета.

Как снизить риск, по возрастанию вмешательства:

- 1. Однопоточный BLAS.** Для матриц 11×11 и нескольких сотен окон многопоточность только мешает. Достаточно задать `ENV OMP_NUM_THREADS=1 OPENBLAS_NUM_THREADS=1 MKL_NUM_THREADS=1` в `Dockerfile` и описать это в `DEPLOY.md`. Переменные должны быть заданы до импорта numru, а `run.py` импортирует numru раньше `classifier.py`, поэтому задавать их изнутри решения поздно. В проверке выше `threadpoolctl.threadpool_limits(1)` во время работы стабильного эффекта не дал.
- 2. Не калибровать после последнего блока.** `fit_block(7)` вызывается после последнего окна: его результат нигде не используется, а время учитывается. Длина сессии известна из `meta["n_samples_eeg"]`. Если после текущего момента не осталось ни одного блока, LOBO можно пропустить. На ответы это не влияет.
- 3. Страховка по времени.** Калибровать только по последним 3–4 блокам, раз в два блока или прерывать LOBO при приближении к бюджету, оставляя предыдущие смещения.
- 4. Выключить калибровку** (`bias.mode = "none"`): -0.003 min-F1 гибрида и -0.005 min-F1 NIRS, зато `fit_block` ≤ 0.65 с даже на медленной машине.

21.3 Прочее

- Docker-образ не собирался:** в среде разработки не было демона Docker. `Dockerfile` не менялся. `.dockerignore` исключает данные и результаты экспериментов.
- CNN не делалась (§20).**
- Идеи для развития:**
 - индивидуальный подбор полос по пику μ в прошлых данных покоя;
 - адаптация глобальной модели к новому человеку внутри сессии: дообучение смещения или масштаба на прошедших блоках;
 - выравнивание NIRS между людьми по аналогии с перецентрированием ЭЭГ и межсубъектная NIRS-модель;
 - короткие каналы NIRS или ЭОГ в будущих записях — они позволили бы честно вычитать системную гемодинамику и взгляд.

ЧАСТЬ IV

Справочник

22. Карта кода

22.1 Рантайм (solution/)

функция / класс	файл	что делает	§
OnlineClassifier	classifier.py	контракт T3; создаёт HybridDecoder с Config.build(artifacts)	1.3
HybridDecoder.__init__	hbci/pipeline.py	фронтенды ЭЭГ/NIRS, начальная матрица M, EMA-объекты, смещения	5.3
HybridDecoder.load	hbci/pipeline.py	глобальная модель + проверка совместимости, fusion.json, прогрев	5.3
HybridDecoder.push	hbci/pipeline.py	передает порции в EEGFrontEnd.push и NIRSFrontEnd.push	6, 9
HybridDecoder.fit_block	hbci/pipeline.py	метки → окна, маска каналов, центр, сессионные модели, глобальный центр, NIRS, калибровка	13
HybridDecoder.predict	hbci/pipeline.py	признаки текущего окна → смесь → слияние → смещения → y , y_{eeg} , y_{nirs}	14
_add_labels	hbci/pipeline.py	сегменты с меткой 1/2/3 → индексы точек сетки внутри них	8.1
_S, _S_current	hbci/pipeline.py	среднее ковариаций по cov_avg_n окнам сетки	6.7
_ref_mean	hbci/pipeline.py	лог-евклидов центр всех прошлых окон с инкрементальным кэшем	7.3
_session_inputs, ts_vector	hbci/pipeline.py	отбеливание, logm, верхний треугольник $\times \sqrt{2} \rightarrow 396$	7.4
_mix	hbci/pipeline.py	смесь сессионной и глобальной модели, $w = k/(k+n)$	8.7
_calibrate_session, _update_bias	hbci/pipeline.py	LOBO-калибровка и усадка смещений	11
EEGFrontEnd.push	hbci/eeg.py	вычитание x_0 , ВЧ, банк полос, ковариации на сетке, счётчик плато	6.1–6.4
EEGFrontEnd.bad_channels	hbci/eeg.py	детектор клиппинга, шумных и «мёртвых» каналов	6.6
spatial_matrix, transform	hbci/eeg.py	матрица M (CAR по чистым, выбор каналов, интерполяция), MSM^T	6.5
StreamingSOS, FilterBank	hbci/filters.py	причинные SOS-фильтры с состоянием	6.2–6.3
shrink_oas, estimate_cov	hbci/riemann.py	усадка OAS + $\epsilon \cdot \text{tr}/p \cdot I$	6.8
logm_spd, invsqrtm_spd, expm_sym	hbci/riemann.py	матричные функции через eigh с ограничением спектра	7.4
fit_linear, _norm_logits, LinearModel	hbci/models.py	sLDA / LR / каскад → numpy-коэффициенты; нормировка логитов	8.2–8.3
fit_ts_mdm, TSMDMModel	hbci/models.py	ближайшее среднее в касательном пространстве, температура	8.4
GlobalEEG	hbci/models.py	загрузка и проверка совместимости межсубъектной модели	8.6
NIRSFrontEnd.push	hbci/nirs.py	НЧ-фильтр, накопленные суммы $\sum x$, $\sum i \cdot x$	9.2

функция / класс	файл	что делает	§
<code>NIRSFrontEnd.mark</code> , <code>counts_at</code>	<code>hbci/nirs.py</code>	запоминание $N(t)$, оценка $N(e)$ для окон блока 1	9.3
<code>NIRSFrontEnd.raw_features</code> , <code>features</code> , <code>_base_W</code>	<code>hbci/nirs.py</code>	наклоны с лагами, линейная комбинация сигналов (контрасты)	9.4
<code>fuse</code>	<code>hbci/fusion.py</code>	лог-линейное слияние / среднее / стекинг	10
<code>calibrate_bias</code> , <code>min_f1_many</code>	<code>hbci/fusion.py</code>	координатный спуск по смещениям, векторный подсчёт min-F1	11
<code>CalLEMA</code>	<code>hbci/smoothing.py</code>	EMA по числу вызовов (в финале $\tau = 0$)	12
<code>Config.build</code> , <code>DEFAULTS</code> , <code>PRESETS</code>	<code>hbci/config.py</code>	сборка конфигурации; пресеты MVP, авторов, контрольных декодеров	5.4
<code>train.py</code>	<code>solution/train.py</code>	офлайн-обучение межсубъектной LR (<code>--mode all</code> / <code>loso</code>)	8.6

22.2 Инструменты и тесты

файл	назначение
<code>tools/run_all.py</code>	официальный прогон каталога сессий через <code>run.py</code> и <code>score.py</code> → <code>results/metrics/</code>
<code>tools/run_experiments.py</code>	сетка конфигураций (<code>OC_CFG</code>), LOSO-артефакты (<code>NBCI_LOSO_DIR</code>), дампы вероятностей
<code>tools/analyze.py</code> , <code>tools/collect_summary.py</code>	F1 по классам, блокам и времени в сегменте, AUC, бутстреп-ДИ → <code>results/summary.md</code>
<code>tools/fit_fusion.py</code> , <code>tools/nested.py</code>	подбор весов слияния по LOSO-дампам; вложенная проверка выбора конфигурации
<code>tools/controls.py</code> , <code>tools/haufe.py</code> , <code>tools/fes_strength.py</code>	пермутационные нули, стратификация по ФЭС, корреляции, паттерны Haufe
<code>tools/eda_figures.py</code> , <code>tools/results_figures.py</code> , <code>tools/make_figures.py</code>	все фигуры <code>results/figures/</code>
<code>tests/*.py</code> , <code>tests/run_all_tests.sh</code>	тесты причинности, инвариантности, изоляции меток, особых сессий, тайминга, LOSO-артефактов (§16)
<code>solution/legacy/</code>	исходный MVP и B1-fix для сравнения

23. Все параметры конфигурации

Значения — после применения `artifacts/config.json` поверх `DEFAULTS`. Жирным выделены параметры, отличающиеся от значений по умолчанию в коде.

ключ	значение в финале	назначение
<code>eeg.features</code>	ts+mdm	<code>ts</code> / <code>logpower</code> / <code>mdm</code> / ts+mdm / <code>csp</code> / <code>heog</code> (контроль)
<code>eeg.channels</code>	<code>sensorimotor11</code>	набор каналов или явный список
<code>eeg.reference</code>	<code>car_clean</code>	<code>none</code> / <code>car_clean</code> / <code>laplacian</code>
<code>eeg.hp_hz</code>	0.5	ВЧ-фильтр, 0 — выключен
<code>eeg.bands</code> , <code>band_order</code>	6 полос 4–30 Гц, 4	банк полосовых фильтров
<code>eeg.cov</code> , <code>cov_eps</code>	<code>oas</code> , <code>1e-4</code>	тип усадки (<code>oas</code> / <code>lw</code> / <code>scm</code>) и регуляризация
<code>eeg.cov_avg_n</code>	5	число окон сетки для усреднения ковариаций
<code>eeg.mean</code>	<code>logeuclid</code>	центр: <code>logeuclid</code> / <code>riemann</code> (Карчер)

ключ	значение в финале	назначение
eeg.classifier, C	sllda, 0.1	сессионный линейный классификатор (sllda / lr)
eeg.logit_T	1	нормировка логитов (None — выключена)
eeg.mdm_T, mdm_metric	1.0, logeuclid	температура и метрика MDM
eeg.train_skip_s	0	пропуск начала сегмента при обучении
eeg.bad_channels, bad_flat_frac, bad_ratio	да, 0.05, 8	детектор плохих каналов
nirs.enabled, features	да, hemo	NIRS-ветка; mvp — признаки исходного MVP
nirs.hp_hz, lp_hz	0, 0.4	фильтры NIRS
nirs.signal, gsr, spatial	hb, нет, channels	HbO+HbR / CBSI / HbO; регрессия глобального сигнала; каналы или области
nirs.slope_s, lags_s	4, [0, 2, 4, 6]	окно наклона и лаги
nirs.use_level, use_slope, lateral	нет, да, да	типы признаков
nirs.level_s, base_tau_s	2, 20	параметры уровней (в финале не используются)
nirs.classifier, logit_T	sllda, 1	NIRS-классификатор (sllda / lr / cascade)
global.enabled, k, recenter	да, 1, all	межсубъектная модель, вес, перецентрирование
smoothing.tau_s, nirs_tau_s	0, 0	сглаживание по вызовам выключено
fusion.mode, w_eeg	loglinear, 0.8	слияние; вес берётся из fusion.json
bias.mode	session	none / global / session
bias.min_blocks, grid, shrink_k, passes	3, [-1.5, 1.5, 0.1], 3, 2	параметры LOBO-калибровки
priors	[1/3, 1/3, 1/3]	априорные вероятности LDA

24. Как запустить и воспроизвести

```
# окружение: Python 3.11, закреплённые версии
pip install -r requirements.txt          # только решение
pip install -r requirements-dev.txt      # + анализ, фигуры, ноутбуки
bash tools/download_data.sh              # data/train/*.mat, data/Montage.mat

# одна сессия — то, что делает проверяющий
python solution/run.py --input <session.mat> --output-dir <out> --artifacts solution/artifacts
python solution/score.py --session <session.mat> --predictions <out>/predictions.csv \
    --timings <out>/timings.csv --output <out>/metrics.json

# официальные метрики на train (один поток — честные тайминги)
python tools/run_all.py --data data/train --out results/metrics -j 1

# глобальная модель: финальная и LOSO-набор для честной оценки
python solution/train.py --mode all --data data/train --out solution/artifacts
python solution/train.py --mode loso --data data/train --out results/artifacts_exp/g_final

# честная LOSO-оценка финала
python tools/run_experiments.py --exp-id E12_final_loso --grid tools/grids/E12_final_loso.json \
    --loso results/artifacts_exp/g_final/loso -j 1 # каталог из train.py --mode loso

# тесты на утечки и сводка
bash tests/run_all_tests.sh python && python tools/run_invariance_all.py
python tools/collect_summary.py && python tools/make_figures.py
```

Ноутбуки с воспроизводимым ходом решения — `assets/01_eda_and_controls.ipynb` и `assets/02_results.ipynb`. Сетки всех экспериментов — `tools/grids/*.json`.

25. Глоссарий

AUC	площадь под ROC-кривой; вероятность, что случайное окно положительного класса получит более высокий балл, чем отрицательного. 0.5 — случайно, 1 — идеально.
BCI / ИМК	интерфейс мозг-компьютер.
CAR	common average reference: из каждого канала вычитается среднее по набору каналов.
CBSI	correlation-based signal improvement: комбинация $\frac{1}{2}(\text{HbO} - \alpha \cdot \text{HbR})$, подавляющая синфазные артефакты NIRS.
CSP / FBCSP	common spatial patterns — пространственные фильтры, максимизирующие отношение дисперсий классов; FB — по банку полос.
EMA	экспоненциальное скользящее среднее.
ERD / ERS	событийно-связанная десинхронизация (падение мощности ритма) и синхронизация (рост, например β -rebound).
HbO / HbR	концентрации окси- и дезоксигемоглобина по данным NIRS.
HRF	гемодинамическая функция ответа: форма изменения кровотока после нейронной активности.
КМП	кинестетическое моторное представление: мысленное воспроизведение ощущений движения.
LDA / sLDA	линейный дискриминантный анализ; s — с усадкой ковариации (Ledoit-Wolf).
LOBO	leave-one-block-out: обучение без одного блока, предсказание его окон.
LOSO	leave-one-subject-out: оценка на испытуемом, не участвовавшем в обучении.
MDM	minimum distance to mean: классификация по ближайшему среднему класса на многообразии.
min-F1	худшая по трём классам F1-мера; главная метрика соревнования.
macro-recall	средняя по классам полнота.
NIRS / fNIRS / БИКС	спектроскопия в ближнем инфракрасном диапазоне — оптическая регистрация гемодинамики коры.
OAS	oracle approximating shrinkage — оценка ковариации с аналитической усадкой к масштабированной единичной матрице.
SOS	second-order sections: запись IIR-фильтра каскадом биквадратных звеньев; численно устойчива.
SPD	симметричная положительно определённая матрица.
касательное пространство	линейное пространство в точке многообразия; логарифмическое отображение переводит SPD-матрицы в векторы.
пересцентрирование	отбеливание ковариаций средним сессии, переносящее «типичное» окно в единичную матрицу.
ФЭС	функциональная электростимуляция мышц.
ГЭОГ	горизонтальная электроокулограмма: сдвиг потенциала при повороте глаз (здесь f7 – f8).

26. Источники

Данные и ближайшие работы

1. Mokienko O., Lukyanov E., Kim L. et al. EEG vs. Hybrid EEG–fNIRS BCI for FES Control in Healthy Subjects: A Blind Randomized Study and an Open Dataset. *Sensors* 26(17):5617, 2026.
doi:10.3390/s26175617 — первоисточник датасета.
2. Fazli S. et al. Enhanced performance by a hybrid NIRS–EEG brain computer interface. *NeuroImage* 59(1):519–529, 2012.
3. Shin J. et al. Open Access Dataset for EEG+NIRS Single-Trial Classification. *IEEE TNSRE* 25(10):1735–1745, 2017.

Физиология

4. Pfurtscheller G., Lopes da Silva F. H. Event-related EEG/MEG synchronization and desynchronization: basic principles. *Clin. Neurophysiol.* 110(11):1842–1857, 1999.
5. Neuper C. et al. Imagery of motor actions: differential effects of kinesthetic and visual–motor mode of imagery in single-trial EEG. *Cogn. Brain Res.* 25(3):668–677, 2005.
6. Yakovlev L., Syrov N., Kaplan A. Investigating the influence of functional electrical stimulation on motor imagery related μ -rhythm suppression. *Front. Neurosci.* 17:1202951, 2023.
7. Abdalmalak A. et al. Using fMRI to investigate the potential cause of inverse oxygenation reported in fNIRS studies of motor imagery. *Neurosci. Lett.* 714:134607, 2020.
8. Tachtsidis I., Scholkmann F. False positives and false negatives in functional near-infrared spectroscopy. *Neurophotronics* 3(3):031405, 2016.
9. Cui X., Bray S., Reiss A. L. Functional near infrared spectroscopy (NIRS) signal improvement based on negative correlation between oxygenated and deoxygenated hemoglobin dynamics. *NeuroImage* 49(4):3039–3046, 2010.

Методы

10. Barachant A., Bonnet S., Congedo M., Jutten C. Multiclass Brain–Computer Interface Classification by Riemannian Geometry. *IEEE TBME* 59(4):920–928, 2012.
11. Congedo M., Barachant A., Bhatia R. Riemannian geometry for EEG-based brain-computer interfaces; a primer and a review. *Brain-Computer Interfaces* 4(3):155–174, 2017.
12. Zanini P. et al. Transfer Learning: A Riemannian Geometry Framework With Applications to Brain–Computer Interfaces. *IEEE TBME* 65(5):1107–1116, 2018.
13. He H., Wu D. Transfer Learning for Brain–Computer Interfaces: A Euclidean Space Data Alignment Approach. *IEEE TBME* 67(2):399–410, 2020.
14. Blankertz B. et al. Single-trial analysis and classification of ERP components — a tutorial. *NeuroImage* 56(2):814–825, 2011 — shrinkage-LDA.
15. Ang K. K. et al. Filter Bank Common Spatial Pattern Algorithm on BCI Competition IV Datasets 2a and 2b. *Front. Neurosci.* 6:39, 2012.
16. Chen Y., Wiesel A., Eldar Y. C., Hero A. O. Shrinkage algorithms for MMSE covariance estimation. *IEEE Trans. Signal Process.* 58(10):5016–5029, 2010 — OAS.
17. Ledoit O., Wolf M. A well-conditioned estimator for large-dimensional covariance matrices. *J. Multivariate Anal.* 88(2):365–411, 2004.
18. Haufe S. et al. On the interpretation of weight vectors of linear models in multivariate neuroimaging. *NeuroImage* 87:96–110, 2014.

19. Lotte F. et al. A review of classification algorithms for EEG-based brain–computer interfaces: a 10 year update. *J. Neural Eng.* 15(3):031005, 2018.
20. Chevallier S. et al. The largest EEG-based BCI reproducibility study for open science: the MOABB benchmark. arXiv:2404.15319, 2024.

Валидация

21. Li R. et al. The Perils and Pitfalls of Block Design for EEG Classification Experiments. *IEEE TPAMI* 43(1):316–333, 2021.
22. Varoquaux G. Cross-validation failure: Small sample sizes lead to large error bars. *NeuroImage* 180:68–77, 2018.
23. Combrisson E., Jerbi K. Exceeding chance level by chance. *J. Neurosci. Methods* 250:126–136, 2015.

Документ составлен по материалам репозитория решения: код `solution/`, отчёт `report/REPORT.md`, research-отчёт `research/RESEARCH_REPORT.md`, журнал `research/WORKLOG.md`, сводка экспериментов `results/summary.md`, метрики `results/metrics/` и `results/experiments/E12_final_loso/`. Все фигуры с результатами взяты из `results/figures/`. Схемы нарисованы для этого документа. Измерение времени в §21.2 выполнено при подготовке документа.